Un lema tipo Borel–Cantelli.

Aplicación a los records

Ricardo Vélez – 2018

1. Lema de Borel–Cantelli

El segundo lema de Borel–Cantelli asegura que si $\{A_n\}$ es una sucesión de sucesos independientes y $\sum \mathrm{P}(A_n) = \infty$, con probabilidad 1, se cumplen infinitos de los sucesos A_n. El siguiente resultado mejora la afirmación anterior.

Teorema 1 *Sea $\{A_n\}$ una sucesión de sucesos independientes dos a dos y S_n el número de sucesos $A_1, \ldots, A_n$ que se verifican. Si $\sum_{n=1}^{\infty} \mathrm{P}(A_n) = \infty$, entonces*

$$\frac{S_n}{\sum_{k=1}^{n} \mathrm{P}\{A_k\}} \longrightarrow 1, \quad \textit{con probabilidad 1.}$$

$\because$ Sea $X_k = \mathbf{I}_{A_k}$, de modo que $S_n = \sum_{k=1}^{n} X_k$ y $\mathrm{E}[S_n] = \sum_{k=1}^{n} P(A_n)$. Como $A_1, \ldots, A_n$ son incorrelados

$$\sigma^2(S_n) = \sum_{k=1}^{n} \sigma^2(X_k) \leq \sum_{k=1}^{n} \mathrm{E}[X_k^2] = \sum_{k=1}^{n} \mathrm{E}[X_k] = \mathrm{E}[S_n].$$

Según la desigualdad de Tchebychev,

$$\mathrm{P}\{|S_n - \mathrm{E}[S_n]| > \varepsilon \mathrm{E}[S_n]\} \leq \frac{\sigma^2(S_n)}{\varepsilon^2 \mathrm{E}[S_n]^2} \leq \frac{1}{\varepsilon^2 \mathrm{E}[S_n]} \longrightarrow 0 \tag{1}$$

Ello indica que $S_n/\mathrm{E}[S_n] \xrightarrow{P} 1$. Ahora bien, sea $n_m = \text{mín}\{n \| \mathrm{E}[S_n] \geq m^2\}$, de forma que $m^2 \leq \mathrm{E}[S_{n_m}] \leq m^2 + 1$, pues $\mathrm{E}[S_{n_m - 1}] \leq m^2$ y $\mathrm{E}[X_{n_m}] \leq 1$. Así, (1) prueba que

$$\mathrm{P}\{|S_{n_m} - \mathrm{E}[S_{n_m}]| > \varepsilon \mathrm{E}[S_{n_m}]\} \leq \frac{1}{\varepsilon^2 k^2},$$

luego $\sum_{m=1}^{\infty} \mathrm{P}\{S_{n_m} - \mathrm{E}[S_{n_m}]| > \varepsilon \mathrm{E}[S_{n_m}]\} < \infty$ y el primer lema de Borel–Cantelli asegura que, con probabilidad 1, solo se cumplen un número finito de dichos sucesos. Dicho de otro modo, $S_{n_m}/\mathrm{E}[S_{n_m}] \longrightarrow 1$ casi seguro. Además, si $n_m \leq n \leq n_{m+1}$,

$$\frac{S_{n_m}}{\mathrm{E}[S_{n_{m+1}}]} \leq \frac{S_n}{\mathrm{E}[S_n]} \leq \frac{S_{n_{m+1}}}{\mathrm{E}[S_{n_m}]}$$

y los extremos tienden c.s. hacia 1, pues $\mathrm{E}[S_{n_{m+1}}]/\mathrm{E}[S_{n_m}] \to 1$ por ser

$$m^2 \leq \mathrm{E}_[S_{n_m}] \leq \mathrm{E}[S_{n_{m+1}}] \leq (m+1)^2 + 1$$

y $(m+1)^2/m^2 \to 1$. $\square$

2. Records

Si $\{X_k\}$ es una sucesión de variables aleatorias independientes e igualmente distribuidas, con distribución continua, ocurre un **record** en la posición r si se verifica el suceso $A_r = \{X_r > X_1, \ldots, X_{r-1}\}$; es decir una mejora de las "marcas" logradas antes del instante r. La continuidad de la distribución evita, con probabilidad 1, que se produzcan empates y la primera marca X_1 siempre es un record.

R_n representará el número de records que tienen lugar entre las n primeras variables.

Es notable que la distribución común de las variables no juega ningún papel en la distribución de los records. Así, el suceso A_r se produce cuando el mayor valor entre $(X_1, X_2, \ldots, X_r)$ ocurre en último lugar. Pero, por simetría, cualquiera de las $r!$ ordenaciones de los r valores tiene la misma probabilidad: $1/r!$ y hay $(r-1)!$ de ellas en las que el máximo está al final. Por consiguiente, $\mathrm{P}(A_r) = 1/r$ para cualquier $r = 1, 2, 3, \ldots$ Con más precisión es cierto que:

Teorema 2 *Los sucesos $\{A_r\}$ son independientes y $\mathrm{P}(A_r) = 1/r \ \forall r \geq 1$.*

$\because$ Evitando pruebas más sintéticas y, considerando las n primeras variables, se puede razonar como sigue. Sean $X_{(1)}, X_{(2)}, \ldots, X_{(n)}$ los n valores ordenados de menor a mayor. Hay sólo el record ocurrido en la posición 1 si $X_1 = X_{(n)}$, estén como estén ordenados los valores de las $n-1$ posiciones restantes; por tanto,

$$\mathrm{P}\{R_n = 1\} = (n-1)!/n! = 1/n.$$

Análogamente, habrá record en todas las posiciones si los valores aparecen ordenados de menor a mayor, es decir

$$\mathrm{P}\{R_n = n\} = 1/n!.$$

En general, para que haya records en las posiciones $1 < r_1 < r_2 < \cdots < r_k$, el mayor valor $X_{(n)}$ tiene que aparecer en la posición r_k (no puede aparecer antes, pues no habría record en la posición r_k, ni puede aparecer después, ya que constituiría un record adicional). Los $n - r_k$ valores posteriores a la posición r_k pueden ser elegidos de $(n-1)(n-2)\cdots r_k = (n-1)!/(r_k-1)!$ formas; es decir, dividiendo por el número total de ordenaciones posibles,

$$\mathrm{P}\Big(A_{r_k} \cap \bigcap_{j=r_k+1}^{n} A_j^c\Big) = \frac{1}{(r_k-1)!\ n}.$$

Para las $r_k - 1$ posiciones anteriores al último record, la situación es la misma; de los $r_k - 1$ valores que quedan, el mayor ha de figurar en la posición r_{k-1} y los valores siguientes, de $r_{k-1}+1$ a $r_k - 1$, pueden elegirse arbitrariamente entre los $r_k - 2$ que quedan; o sea

$$\mathrm{P}\Big(A_{r_{k-1}} \cap A_{r_k} \cap \bigcap_{\substack{j=r_{k-1}+1 \\ j \neq r_k}}^{n} A_j^c\Big) = \frac{(r_k-2)!}{(r_{k-1}-1)!}\,\frac{1}{(r_k-1)!\ n} = \frac{1}{(r_{k-1}-1)!(r_k-1)n}.$$

Procediendo de igual forma con los records anteriores, se llega a

$$\mathrm{P}\Big(A_{r_1} \cap \cdots \cap A_{r_k} \cap \bigcap_{\substack{2\le j\le n\\ j\ne r_1,\dots,r_k}} A_j^c\Big) = \frac{1}{(r_1-1)\cdots(r_k-1)n} = \frac{1}{r_1\dots r_k} \prod_{\substack{2\le j\le n\\ j\ne r_1,\dots,r_k}} \frac{j-1}{j}$$

lo cual muestra la independencia de $A_1,\dots,A_n$. $\square$

Según lo anterior, la función generatriz de R_n es

$$\mathrm{E}[z^{R_n}] = \prod_{r=1}^{n}\Big(1-\frac{1}{r}+\frac{z}{r}\Big) = \frac{1}{n!}z(z+1)(z+2)\cdots(z+n).$$

Para n fijo, la expansión del polinomio, que realizan los programas de cálculo por ordenador, facilita las probabilidades de los distintos números de records. Alternativamente, si $u = z-1$, es

$$\mathrm{E}[z^{R_n}] = \prod_{r=1}^{n}\Big(1+\frac{u}{r}\Big) = 1 + u\sum_{1\le r\le n} r^{-1} + u^2 \sum_{1\le r_1<r_2\le n} (r_1r_2)^{-1} + \cdots$$

así que la expansión del polinomio en u permite obtener todos los momentos de R_n. En particular, como es obvio, $\mathrm{E}[R_n] = \sum_{r=1}^{n} r^{-1} \sim \log n$ ([1]).
Cuando $n\to\infty$, el Teorema 1 permite concluir:

Corolario 3 *El número R_n de records entre las n primeras variables verifica*

$$R_n/\log n \longrightarrow 1 \qquad \textit{casi seguro.}$$

Referencias

(1) Durrett, R. (2010): *Probability: Theory and Examples.* Cambridge University Press. (Chapter 2, Section 2.3).

[1] Véase *Cálculo de Probabilidades 1*, pág. 458.