

Principio de las Grandes Desviaciones y Aplicaciones



Sathamangalam Ranga Iyengar Srinivasa Varadhan
1940 –

Ricardo Vélez
2017

Índice

1. Principio de las grandes desviaciones	3
1.1. El principio de Laplace	6
2. Teorema de Sanov	9
2.1. Teoría de la información y entropía	9
2.2. El caso general	11
3. Aplicaciones a la Física Estadística	18
3.1. Gases ideales	18
3.2. Ferromagnetismo. Modelo de Curie-Weiss	20
4. Teorema de Gärtner–Ellis	23

1. Principio de las grandes desviaciones

A partir del Teorema de Varadhan acerca de las Grandes Desviaciones de las sumas de variables aleatorias independientes e igualmente distribuidas, la investigación adquirió un carácter más abstracto, pero que ha mostrado una gran cantidad de aplicaciones y, en particular, una estrecha relación con algunos aspectos de la Física Estadística.

El concepto general que sirve de inicio de la teoría es el siguiente.

En un espacio métrico E , una función $I : E \mapsto [0, \infty]$ se denomina una **función tasa** si $\{a \in E : I(a) \leq c\}$ es un conjunto cerrado para cualquier $c \geq 0$ ⁽¹⁾. La tasa I es **compacta** si $\{a \in E : I(a) \leq c\}$ es compacto $\forall c \in \mathbb{R}$. Se representa $I(A) = \inf_{a \in A} I(a)$.

Una sucesión $\{X_n\}$ de variables aleatorias con valores en E satisface el **Principio de las grandes desviaciones (P.G.D.)** con velocidad $v_n \rightarrow \infty$ y tasa I si, para cualquier conjunto de Borel A , se cumple

$$\limsup_n \frac{1}{v_n} \log P\{X_n \in A\} \leq -I(\bar{A}) \quad (1)$$

$$\liminf_n \frac{1}{v_n} \log P\{X_n \in A\} \geq -I(A^\circ). \quad (2)$$

donde $\bar{A}$ es el cierre de A y A° su interior.

En este sentido, los resultados obtenidos en *Grandes Desviaciones de las sumas de v.a.i.i.d.* afirman que los promedios $\bar{X}_n = S_n/n$ satisfacen el P.G.D. con velocidad n y tasa compacta $I(a) = \kappa^*(a) = \sup_\theta \{a\theta - \kappa(\theta)\}$, donde $\kappa(\theta) = \log E[e^{\theta X}]$.

Lo más normal es considerar la velocidad $v_n = n$.

Sea $\mathcal{C}_I$ la clase de los conjuntos de Borel A tales que $I(A^\circ) = I(\bar{A})$. Desde luego el P.G.D. implica que

$$\lim_n \frac{1}{n} \log P\{X_n \in A\} = -I(A) \quad \forall A \in \mathcal{C}_I. \quad (3)$$

La exigencia de que I sea semicontinua inferiormente permite probar:

Proposición 1 Si $\{X_n\}$ verifica P.G.D., la tasa $I(a)$ es única.

$\because$ Como $A_c = \{a : I(a) > c\}$ es abierto, para cada $c < I(a_0)$ existe $B(a_0, \varepsilon) \subset A_c$, con lo cual $I(B(a_0, \varepsilon)) > c$; por consiguiente, $\lim_{\varepsilon \downarrow 0} I(B(a_0, \varepsilon)) \geq I(a_0)$, o mejor dicho, $\lim_{\varepsilon \downarrow 0} I(B(a_0, \varepsilon)) = I(a_0)$ ya que la desigualdad contraria es inmediata.

Ahora bien, $I(B(a_0, \varepsilon))$ es una función positiva y decreciente de ε que solo puede tener un número numerable de discontinuidades; así que para la mayoría de valores de ε es $I(B(a_0, \varepsilon)) = I(\bar{B}(a_0, \varepsilon))$ y se cumple

$$I(B(a_0, \varepsilon)) = -\lim_n \frac{1}{n} \log P\{X_n \in B(a_0, \varepsilon)\}.$$

¹ Ello equivale a que $I(a)$ sea semicontinua inferiormente: $\liminf_{a \rightarrow a_0} I(a) \geq I(a_0)$.

Esto determina $I(B(a_0, \varepsilon))$ para casi todos los valores de ε y, por tanto, $I(a_0)$ está determinada. $\square$

Nótese que, si I es una tasa compacta para el P.G.D. de una sucesión $\{X_n\}$, ha de ser $I(a) = 0$ para algún $a \in E$. De hecho, $\frac{1}{n} \log P\{X_n \in E\} \equiv 0$ luego $I(E) = 0$; pero $I(E) = \inf_{\{a: I(a) \leq 1\}} I(a)$ y la función semicontinua inferiormente $I(a)$ alcanza su mínimo en el compacto $\{I(a) \leq 1\}$. Además, $N = \{a \in E : I(a) = 0\}$ es un conjunto compacto y, si $\bar{A} \cap N = \emptyset$, es $I(\bar{A}) > 0$ (pues si fuese $I(\bar{A}) = 0$ existiría una sucesión $a_n \in \bar{A}$ con $a_n \rightarrow a \in \bar{A}$ e $I(a) = 0$, de forma que $a \in \bar{A} \cap N$). Para tales conjuntos A es $P\{X_n \in A\} \leq e^{-nI(\bar{A})}$ para todo n suficientemente grande.

Proposición 2 $\{X_n\}$ verifica P.G.D. con tasa I si y sólo si se cumple

$$\limsup_n \frac{1}{n} \log P\{X_n \in A\} \leq -I(A) \quad \text{para todo } A \text{ cerrado}, \quad (4)$$

$$\liminf_n \frac{1}{n} \log P\{X_n \in A\} \geq -I(A) \quad \text{para todo } A \text{ abierto}. \quad (5)$$

$\therefore$ Para cualquier A es $A \subset \bar{A}$ y $\bar{A}$ es cerrado, luego según (4)

$$\limsup_n \frac{1}{n} \log P\{X_n \in A\} \leq \limsup_n \frac{1}{n} \log P\{X_n \in \bar{A}\} \leq -I(\bar{A}).$$

Análogamente A° es abierto y $A^\circ \subset A$, luego según (5)

$$\liminf_n \frac{1}{n} \log P\{X_n \in A\} \geq \liminf_n \frac{1}{n} \log P\{X_n \in A^\circ\} \geq -I(A^\circ).$$

Recíprocamente, es inmediato que (4) se sigue de (1) y (5) se sigue de (2). $\square$

Proposición 3 Cuando I es una tasa compacta, (3) basta para que se cumpla P.G.D.

$\therefore$ Sea A^ε el conjunto cerrado de los a que distan de A menos o igual que $\varepsilon > 0$. Como A^ε crece con ε , $I(A^\varepsilon)$ es positiva y decreciente, así que es continua excepto a lo sumo para un número numerable de valores de ε ; en el resto $A^\varepsilon \in \mathcal{C}_I$ y, según (3),

$$\limsup_n \frac{1}{n} \log P\{X_n \in A\} \leq \lim_n \frac{1}{n} \log P\{X_n \in A^\varepsilon\} = -I(A^\varepsilon).$$

Cuando $\varepsilon \downarrow 0$ es $I(A^\varepsilon) \uparrow I(\bar{A})$ pues, si fuese $I(A^\varepsilon) \uparrow c < I(\bar{A})$, para cada ε existiría $a_\varepsilon \in A^\varepsilon$ con $I(a_\varepsilon) \leq c$; pero, dado que $\{I(a) \leq c\}$ es compacto, existe una sucesión convergente $a_{\varepsilon_n} \rightarrow a^*$ y tiene que ser $a^* \in \bar{A}$. Luego $I(a^*) \leq \liminf_n I(a_{\varepsilon_n}) \leq c$, lo cual es una contradicción puesto que $I(\bar{A}) \leq I(a^*)$. Así pues, (1) se obtiene haciendo $\varepsilon \downarrow 0$.

Por otro lado, para cualquier $a \in A^\circ$ es $B(a, \varepsilon) \subset A^\circ$ para ε suficientemente pequeño y, siempre que $B(a, \varepsilon) \in \mathcal{C}_I$ (lo cual ocurre salvo para un número numerable de valores de ε) será

$$-I(a) \leq -I(B(a, \varepsilon)) = \lim_n \frac{1}{n} \log P\{X_n \in B(a, \varepsilon)\} \leq \liminf_n \frac{1}{n} \log P\{X_n \in A\};$$

de donde se obtiene (2) puesto que $a \in A^\circ$ es arbitrario. $\square$

Proposición 4 Si $\{X_n\}$ verifica P.G.D. con tasa I y $f : E \mapsto E'$ es una función continua de E en otro espacio métrico E' , $\{Y_n = f(X_n)\}$ verifica P.G.D. con tasa $J(b) = I(f^{-1}(b)) = \inf_{a \in f^{-1}(b)} I(a)$ ⁽²⁾. Además, J es compacta si lo es I .

$\therefore$ Como $\overline{f^{-1}(A)} \subset f^{-1}(\bar{A})$, es

$$\begin{aligned} \limsup_n \frac{1}{n} \log P\{Y_n \in A\} &= \limsup_n \frac{1}{n} \log P\{X_n \in f^{-1}(A)\} \leq -I(\overline{f^{-1}(A)}) \\ &\leq -I(f^{-1}(\bar{A})) = -\inf_{b \in \bar{A}} I(f^{-1}(b)) = -J(\bar{A}). \end{aligned}$$

Por otra parte, como $f^{-1}(A^\circ) \subset f^{-1}(A)^\circ$, es

$$\begin{aligned} \liminf_n \frac{1}{n} \log P\{Y_n \in A\} &= \liminf_n \frac{1}{n} \log P\{X_n \in f^{-1}(A)\} \geq -I(f^{-1}(A)^\circ) \\ &\geq -I(f^{-1}(A^\circ)) = -\inf_{b \in A^\circ} I(f^{-1}(b)) = J(A^\circ). \end{aligned}$$

Finalmente, supuesto que $\{a \in E : I(a) \leq c\}$ es compacto, se verifica

$$f(\{a \in E : I(a) \leq c\}) = \{f(a) : I(a) \leq c\} = \{b \in E' : I(f^{-1}(b)) \leq c\}$$

pues, si $b = f(a)$ con $I(a) \leq c$, es $a \in f^{-1}(b)$ y $I(f^{-1}(b)) \leq I(a) \leq c$; y al revés, si $I(f^{-1}(b)) \leq c$, $f^{-1}(b)$ es un cerrado no vacío cuya intersección con el compacto $\{I(a) \leq c + 1\}$ es un compacto en el que se alcanza el $\inf_{a \in f^{-1}(b)} I(a)$, o sea que existe $a_0 \in f^{-1}(b)$ con $I(a_0) = J(b)$. Como la imagen de un compacto por una aplicación continua es un compacto, resulta que J es una tasa compacta. $\square$

El resultado en sentido contrario se cumple si la sucesión $\{X_n\}$ está **exponencialmente acotada** ⁽³⁾, en el sentido siguiente:

Para todo $c > 0$ existe un compacto K_c tal que

$$\limsup_n \frac{1}{n} \log P\{X_n \notin K_c\} < -c. \quad (6)$$

Proposición 5 Si $\{X_n\}$ es exponencialmente acotada y satisface (4) sólo para conjuntos A compactos y (5), se verifica P.G.D y la tasa es compacta.

$\therefore$ Para cualquier cerrado A será

$$P\{X_n \in A\} \leq 2 \max\{P\{X_n \in A \cap K_c\}, P\{X_n \notin K_c\}\}$$

con lo cual, en virtud de las hipótesis, resulta

$$\limsup_n \frac{1}{n} \log P\{X_n \in A\} \leq -\min\{I(A \cap K_c), c\}.$$

Si $c \rightarrow \infty$, $K_c \uparrow E$ y se obtiene (4). Además, como K_c^c es abierto, según (5) es

$$-I(K_c^c) \leq \liminf_n \frac{1}{n} \log P\{X_n \notin K_c\} < -c$$

de manera que $\{a : I(a) \leq c\} \subset K_c$ es compacto. $\square$

² Con el convenio $J(\emptyset) = \infty$ para el caso en que $b \notin f(E)$.

³ “exponentially tight”, en terminología inglesa.

Proposición 6 Sea $\{X_n\}$ exponencialmente acotada y $f : E \mapsto E'$ continua e inyectiva, si $\{Y_n = f(X_n)\}$ cumple P.G.D. con tasa J , también $\{X_n\}$ cumple P.G.D. con tasa compacta $I(a) = J(f(a))$.

$\therefore$ Como $C = \{b : J(b) \leq c\}$ es cerrado, $\{a : I(a) \leq c\} = \{a : J(f(a)) \leq c\} = f^{-1}(C)$ también es cerrado e I es una función tasa.

La comprobación de (4) cuando A es un compacto de E utiliza que $f(A)$ es también compacto en E' , luego

$$\limsup_n \frac{1}{n} \log P\{X_n \in A\} = \limsup_n \frac{1}{n} \log P\{Y_n \in f(A)\} \leq -J(f(A)) = -I(A).$$

Para A abierto en E , si $a \in A$ e $I(a) = c$, sea K_c un compacto que cumpla (6); como $f(K_c)$ es compacto, (5) indica que

$$\begin{aligned} -I(K_c^c) &= -J(f(K_c^c)) \leq -J(f(K_c)^c) \leq \liminf_n \frac{1}{n} \log P\{Y_n \notin f(K_c)\} \\ &\leq \limsup_n \frac{1}{n} \log P\{X_n \notin K_c\} < -c \end{aligned}$$

con lo cual $a \in K_c$. La función f es biyectiva entre K_c y $f(K_c)$ y f^{-1} es también continua (porque, si $b_n \rightarrow b$, $a_n = f^{-1}(b_n)$ y $a = f^{-1}(b)$, cualquier sucesión convergente $a_{n'} \rightarrow a'$ es tal que $b_{n'} \rightarrow f(a') = b$, luego $a' = a$; o sea que $a_n \rightarrow a$). Entonces el abierto relativo $A \cap K_c$ se transforma en un abierto relativo $B \cap f(K_c)$ y será

$$P\{Y_n \in B\} \leq P\{X_n \in A\} + P\{X_n \notin K_c\}$$

de manera que, como $f(a) \in B$, será

$$\begin{aligned} -c &= -I(a) = -J(f(a)) \leq \liminf_n \frac{1}{n} \log P\{Y_n \in B\} \\ &\leq \max \left\{ \liminf_n \frac{1}{n} \log P\{X_n \in A\}, \limsup_n \frac{1}{n} \log P\{X_n \notin K_c\} \right\}. \end{aligned}$$

Pero, dado que el segundo término es inferior a $-c$, tiene que ser

$$\liminf_n \frac{1}{n} \log P\{X_n \in A\} \geq -c = -I(a)$$

y (5) se sigue de ser $a \in A$ arbitrario. Una vez probado (4) para compactos y (5), la proposición anterior asegura que $\{X_n\}$ cumple P.G.D. e I es compacta. $\square$

1.1. El principio de Laplace

Un resultado clásico, debido a Laplace, afirma que si $f : [0, 1] \mapsto \mathbb{R}$ es continua y acotada

$$\int_0^1 e^{-nf(x)} dx \sim e^{-n \min f(x)}.$$

Debido a ello la siguiente definición se conoce como **Principio de Laplace**:

Una sucesión $\{X_n\}$ de variables aleatorias (con valores en E) verifica el Principio de Laplace con tasa I si, para toda función $f : E \mapsto \mathbb{R}$ continua y acotada se cumple

$$\lim_n \frac{1}{n} \log E[e^{-nf(X_n)}] = - \inf_{a \in E} \{f(a) + I(a)\}. \quad (7)$$

Resulta que el P.G.D. y el *Principio de Laplace* son equivalentes cuando la tasa I es compacta. La implicación directa no precisa que I sea compacta.

Teorema 7 (Varadhan) *Si $\{X_n\}$ cumple el P.G.D. con tasa I , también cumple el Principio de Laplace con la misma tasa I . Más exactamente, para cualquier f continua y acotada, de (1) se sigue*

$$\limsup_n \frac{1}{n} \log E[e^{-nf(X_n)}] \leq - \inf_{a \in E} \{f(a) + I(a)\},$$

mientras que (2) implica

$$\liminf_n \frac{1}{n} \log E[e^{-nf(X_n)}] \geq - \inf_{a \in E} \{f(a) + I(a)\}.$$

$\therefore$ Para probar la primera acotación, sea $K > |f(a)| \forall a \in E$ y, para cualquier $N \in \mathbb{N}$ y $j = 1, 2, \dots, N$ considérense los cerrados

$$C_{N,j} = \{a \in E : -K + 2(j-1)K/N \leq -f(a) \leq -K + 2jK/N\}.$$

Entonces, según (1) y usando el lema de Laplace ⁽⁴⁾, será

$$\begin{aligned} \limsup_n \frac{1}{n} \log E[e^{-nf(X_n)}] &\leq \limsup_n \frac{1}{n} \log \sum_{j=1}^N E[e^{-nf(X_n)} \mathbf{I}_{\{X_n \in C_{N,j}\}}] \\ &\leq \max_{j \leq N} \{-K + 2jK/N - I(C_{N,j})\} \\ &\leq \max_{j \leq N} \sup_{a \in C_{N,j}} \{-f(a) - I(a)\} + 2K/N \\ &= \sup_{a \in E} \{-f(a) - I(a)\} + 2K/N \end{aligned}$$

y basta hacer $N \rightarrow \infty$.

Para la segunda implicación, para cualquier $a \in E$ y cualquier $\varepsilon > 0$, sea A el abierto $\{b \in E : f(b) < f(a) + \varepsilon\}$ y será

$$\begin{aligned} \liminf_n \frac{1}{n} \log E[e^{-nf(X_n)}] &\geq \liminf_n \frac{1}{n} \log E[e^{-nf(X_n)} \mathbf{I}_{\{X_n \in A\}}] \\ &\geq -f(a) - \varepsilon + \liminf_n \frac{1}{n} \log P\{X_n \in A\} \\ &\geq -f(a) - \varepsilon - I(A) \geq -f(a) - I(a) - \varepsilon \end{aligned}$$

con lo cual basta hacer $\varepsilon \downarrow 0$ y tener en cuenta que a es arbitrario. $\square$

Cuando la tasa es compacta, es válido el recíproco del teorema anterior:

Teorema 8 *Si $\{X_n\}$ cumple el Principio de Laplace con tasa compacta I , también cumple el P.G.D. con la misma tasa I .*

$\therefore$ Para probar (4), sea A un cerrado de E y $\chi(a) = 0$ en A , $\chi(a) = \infty$ en A^c . Representando por $d(a, A)$ la distancia de a a A , χ puede aproximarse por las

⁴ Lema 6 en *Grandes desviaciones de las sumas de v.a.i.i.d.*

funciones $f_k(a) = k \min\{d(a, A), 1\}$ que son continuas, acotadas y crecen hacia χ . Por tanto

$$\frac{1}{n} \log P\{X_n \in A\} = \frac{1}{n} \log E[e^{-n\chi(X_n)}] \leq \frac{1}{n} \log E[e^{-nf_k(X_n)}]$$

y, en consecuencia,

$$\limsup_n \frac{1}{n} \log P\{X_n \in A\} \leq \lim_n \frac{1}{n} \log E[e^{-nf_k(X_n)}] = - \inf_{a \in E} \{f_k(a) + I(a)\}.$$

Pero, como $f_k(a) = 0$ cuando $a \in A$, es

$$\inf_{a \in E} \{f_k(a) + I(a)\} = \min \{I(A), \inf_{a \in A^c} \{f_k(a) + I(a)\}\} \leq I(A)$$

luego $\limsup_k \inf_{a \in E} \{f_k(a) + I(a)\} \leq I(A)$. Además, si fuese $I(A) \in (0, \infty)$ y

$$\liminf_k \inf_{a \in A^c} \{f_k(a) + I(a)\} < I(A) \quad \text{sería} \quad \inf_{a \in A^c} \{f_{k'}(a) + I(a)\} \leq I(A) - 2\varepsilon$$

para cierto $\varepsilon \in (0, I(A)/2)$, a lo largo de una subsucesión k' . Entonces, tendrían que existir $a_{k'} \in A^c$ tales que

$$f_{k'}(a_{k'}) + I(a_{k'}) \leq I(A) - \varepsilon$$

y debe ser $d(a_{k'}, A) \rightarrow 0$ pues, si no $f_{k'}(a_{k'}) \rightarrow \infty$. Es decir que existen $b_{k'} \in A$ con $d(a_{k'}, b_{k'}) \rightarrow 0$ y $b_{k'}$ tiene un punto de acumulación $b^* \in A$ para el cual hay una subsucesión k'' tal que $a_{k''} \rightarrow b^*$; por tanto, $I(b^*) \leq I(A) - \varepsilon$, puesto que el conjunto $\{I(a) \leq I(A) - \varepsilon\}$ es compacto. Ello contradice que $I(b^*) \geq I(A)$ por ser $b^* \in A$. En resumen, $\lim_k \inf_{a \in A^c} \{f_k(a) + I(a)\} = I(A)$ y (4) queda probado.

Un razonamiento similar vale cuando $I(A) = \infty$, mientras que si $I(A) = 0$ la conclusión es trivial puesto que $\inf_{a \in E} \{f_k(a) + I(a)\} \geq 0$.

Para establecer (5), supongamos que A es abierto e $I(A) < \infty$ (ya que la conclusión es trivial para $I(A) = \infty$). Para todo $a \in A$ tal que $I(a) < \infty$, existe $K > I(a)$ y $\varepsilon > 0$ tal que $B(a, \varepsilon) \subset A$. Sea

$$f(b) = K \min\{d(a, b)/\varepsilon, 1\}$$

función continua y acotada que cumple $f(a) = 0$, $f(b) = K$ en $B(a, \varepsilon)^c$ y siempre $0 \leq f(b) \leq K$. Entonces

$$\begin{aligned} E[e^{-nf(X_n)}] &\leq e^{-nK} P\{X_n \in B(a, \varepsilon)^c\} + P\{X_n \in B(a, \varepsilon)\} \\ &\leq e^{-nK} + P\{X_n \in B(a, \varepsilon)\} \leq 2 \max\{e^{-nK}, P\{X_n \in B(a, \varepsilon)\}\} \end{aligned}$$

con lo cual

$$\begin{aligned} \max\{\liminf_n \frac{1}{n} \log P\{X_n \in B(a, \varepsilon)\}, -K\} &\geq \lim_n \frac{1}{n} \log E[e^{-nf(X_n)}] \\ &= - \inf_{b \in E} \{f(b) + I(b)\} \geq -I(a). \end{aligned}$$

Como $I(a) > K$ y $B(a, \varepsilon) \subset A$, resulta

$$\liminf_n \frac{1}{n} \log P\{X_n \in A\} \geq \liminf_n \frac{1}{n} \log P\{X_n \in B(a, \varepsilon)\} \geq -I(a)$$

y, como ello es cierto para todo $a \in A$ con $I(a) < \infty$, se obtiene

$$\liminf_n \frac{1}{n} \log P\{X_n \in A\} \geq -I(A). \quad \square$$

2. Teorema de Sanov

Antes de exponer el resultado principal de esta sección, conviene introducir algunas ideas elementales relativas a uno de los contextos en los que se aplica con frecuencia.

2.1. Teoría de la información y entropía

En teoría de la información se considera un alfabeto $\Gamma = \{a_1, a_2, \dots, a_r\}$ con el que se forman mensajes o palabras de longitud fija n , de modo que el conjunto de todos los mensajes posibles es $\Gamma^n = \{\omega = (\omega_1, \dots, \omega_n) : \omega_i \in \Gamma \forall i \leq n\}$.

No todos los mensajes se utilizan con igual frecuencia, sino que $\mathbf{p} = (p_1, p_2, \dots, p_r)$ son las probabilidades con las que aparece cada letra y, en primera aproximación, el mensaje se compone de n letras elegidas independientemente con distribución $\mathbf{p}$. Por consiguiente, la probabilidad del mensaje ω es $\mathbf{p}(\omega) = p_1^{n_1} p_2^{n_2} \cdots p_r^{n_r}$ siendo n_i el número de veces que figura la letra a_i en ω .

Shannon definió la **entropía** de la distribución $\mathbf{p}$ mediante

$$H(\mathbf{p}) = - \sum_{i=1}^r p_i \log p_i \quad (8)$$

que es una función positiva, cóncava, que alcanza su máximo (sujeto a $\sum_i p_i = 1$) cuando es $p_i = 1/r \forall i \leq r$, con el valor $\max_{\mathbf{p}} H(\mathbf{p}) = \log r$. La interpretación es que un resultado de probabilidad $p \simeq 1$ es bastante anodino y $-\log p$ es pequeño; en cambio, un resultado con $p \simeq 0$ es muy peculiar y $-\log p$ es muy grande. Así, $H(\mathbf{p})$ expresa la información esperada al elegir una letra con la distribución $\mathbf{p}$. Además, gracias al logaritmo, la información obtenida al elegir independientemente dos resultados, con probabilidades respectivas $\mathbf{p}$ y $\mathbf{q}$, es la suma de las informaciones obtenidas con cada uno: $H(\mathbf{p} \times \mathbf{q}) = H(\mathbf{p}) + H(\mathbf{q})$.

Una idea básica en el desarrollo de Shannon es establecer el *Principio de equipartición asintótica* (AEP). Según la ley débil de los grandes números, para todo $\varepsilon > 0$, con probabilidad mayor que $1 - \varepsilon$ es

$$-\frac{1}{n} \log \mathbf{p}(\omega) = -\frac{1}{n} \sum_{k=1}^n \log p(\omega_k) \in (H(\mathbf{p}) - \varepsilon, H(\mathbf{p}) + \varepsilon)$$

si n es suficientemente grande, puesto que $E[\log p(\omega_k)] = \sum_{j=1}^r p_j \log p_j = -H(\mathbf{p})$. Por consiguiente, el conjunto de mensajes

$$\Gamma_n(\varepsilon) = \{\omega \in \Gamma^n : e^{-n[H(\mathbf{p})+\varepsilon]} \leq \mathbf{p}(\omega) \leq e^{-n[H(\mathbf{p})-\varepsilon]}\}$$

tiene las siguientes propiedades:

- $\mathbf{p}(\omega)$ es aproximadamente constante en $\Gamma_n(\varepsilon)$, si ε es pequeño.
- $\mathbf{p}(\Gamma_n(\varepsilon)) > 1 - \varepsilon$, si n es suficientemente grande.
- $(1 - \varepsilon)e^{n[H(\mathbf{p})-\varepsilon]} \leq |\Gamma_n(\varepsilon)| \leq e^{n[H(\mathbf{p})+\varepsilon]}$, siendo $|\Gamma_n(\varepsilon)|$ el cardinal de $\Gamma_n(\varepsilon)$.

Esta última propiedad resulta de las desigualdades:

$$1 \geq \sum_{\omega \in \Gamma_n(\varepsilon)} \mathbf{p}(\omega) \geq e^{-n[H(\mathbf{p})+\varepsilon]} |\Gamma_n(\varepsilon)|$$

$$1 - \varepsilon < \mathbf{p}(\Gamma_n(\varepsilon)) \leq e^{-n[H(\mathbf{p})-\varepsilon]} |\Gamma_n(\varepsilon)|.$$

Esto significa que existe un “pequeño” número de mensajes, que tienen similar probabilidad de ocurrir, entre los cuales hay una alta probabilidad de que esté cualquier mensaje formado a partir de las probabilidades $\mathbf{p}$ (eligiendo las letras con independencia y distribución $\mathbf{p}$). Lo pequeño que es el conjunto $\Gamma_n(\varepsilon)$ depende de la entropía $H(\mathbf{p})$; concretamente $|\Gamma_n(\varepsilon)|/|\Gamma^n| \approx e^{-n[\log r - H(\mathbf{p})]}$, de modo que si $\mathbf{p}$ es próxima a la distribución uniforme en Γ , es $|\Gamma_n(\varepsilon)|/|\Gamma^n| \approx 1$. En cambio, si $H(\mathbf{p}) \approx \frac{1}{2} \log r$, es $|\Gamma_n(\varepsilon)| \approx \sqrt{r^n}$ frente a $|\Gamma^n| = r^n$.⁽⁵⁾

Las conclusiones anteriores, fruto de la Ley de los grandes números, especifican cuál es el conjunto de los mensajes “típicos” –aquellos que aparecen con mayor frecuencia. Sin embargo, el propósito de la teoría de las grandes desviaciones es analizar cómo decaen las probabilidades de los mensajes “atípicos” a medida que su longitud, n , aumenta. En ese objetivo juega un papel importante la **entropía relativa**, definida por

$$H(\mathbf{q}||\mathbf{p}) = \sum_{i=1}^r q_i \log \frac{q_i}{p_i} \quad (9)$$

para cada distribución $\mathbf{q}$ sobre Γ ; es decir, en el conjunto

$$\Delta = \{\mathbf{q} \in \mathbb{R}^r : q_i \in [0, 1] \forall i \leq r \text{ y } \sum_{i=1}^r q_i = 1\}.$$

Si ξ es la variable aleatoria que toma los valores p_i/q_i , con probabilidades respectivas q_i , en virtud de la desigualdad de Jensen, es

$$H(\mathbf{q}||\mathbf{p}) = -\mathbb{E}_{\mathbf{q}}[\log \xi] \geq -\log \mathbb{E}_{\mathbf{q}}[\xi] = -\log \sum_{i=1}^r p_i = 0,$$

con igualdad si $\mathbf{q} = \mathbf{p}$. En este sentido $H(\mathbf{q}||\mathbf{p})$ mide la divergencia (no es una distancia) entre $\mathbf{q}$ y $\mathbf{p}$, denominada también *divergencia de Kullback–Leibler*. Si $\mathbf{u}$ es la distribución uniforme en Γ , la entropía de Shannon resulta

$$H(\mathbf{p}) = \log r - H(\mathbf{p}||\mathbf{u}). \quad (10)$$

Consideremos ahora las variables aleatorias $X_k(\boldsymbol{\omega}) = \omega_k$ que indican la letra que figura en cada posición del mensaje $\boldsymbol{\omega}$, sobre las cuales se supone que son independientes e igualmente distribuidas con distribución $\mathbf{p}$. Para cada $i = 1, \dots, r$, las variables $Y_k(a_i) = \mathbf{I}_{\{X_k=a_i\}}$ son asimismo independientes e igualmente distribuidas, siendo $\mathbb{P}\{Y_k(a_i) = 1\} = p_i$. Además $\bar{Y}_n(a_i) = \frac{1}{n} \sum_{k=1}^n Y_k(a_i)$ proporciona la frecuencia de la letra a_i dentro de la secuencia $\boldsymbol{\omega}$. Es decir, $\bar{Y}_n(a_i) = n_i/n$ siendo n_i el número de veces que figura a_i en $\boldsymbol{\omega}$, de modo que

$$\bar{\mathbf{Y}}_n = [\bar{Y}_n(a_1), \dots, \bar{Y}_n(a_r)] \in \Delta.$$

Es consecuencia de la Ley de los grandes números que $\bar{\mathbf{Y}}_n \xrightarrow{c.s.} \mathbf{p}$ cuando $n \uparrow \infty$ (puesto que p_i es la media de $\bar{Y}_n(a_i)$ para todo $i = 1, \dots, r$). Sin embargo, la teoría de las Grandes Desviaciones consiste en estudiar como decrecen las probabilidades de que el azar sitúe $\bar{\mathbf{Y}}_n$ dentro de un conjunto de distribuciones más o menos alejado de $\mathbf{p}$. Eso es lo que indica el resultado siguiente.

⁵ El AEP puede extenderse a situaciones más generales que la independencia e igual distribución de los símbolos del mensaje. Con símbolos independientes (no igualmente distribuidos), la conclusión sigue basándose en las leyes de los grandes números. Con símbolos idénticamente distribuidos (no independientes), constituye el Teorema de Shannon–McMillan–Breiman, integrado en la *Teoría Ergódica* y mucho más difícil de probar.

Teorema 9 (Sanov. Caso discreto) Si A es cualquier subconjunto de Borel convexo de Δ ,

$$\lim_n \frac{1}{n} \log P\{\bar{\mathbf{Y}}_n \in A\} = - \inf_{\mathbf{q} \in A} H(\mathbf{q} \parallel \mathbf{p}). \quad (11)$$

La existencia del límite es consecuencia del Teorema de Cramér ⁽⁶⁾. Por otro lado

$$\kappa(\boldsymbol{\theta}) = \log E[e^{\boldsymbol{\theta} \mathbf{Y}_1}] = \log (p_1 e^{\theta_1} + \dots + p_r e^{\theta_r})$$

puesto que $\mathbf{Y}_1$ puede tomar el valor $\boldsymbol{\delta}_i = (\delta_{i,1}, \dots, \delta_{i,r})$ con probabilidad p_i , para cada $i = 1, \dots, r$. Entonces, la transformada de Legendre de κ es

$$\kappa^*(\mathbf{q}) = \sup_{\boldsymbol{\theta}} [\boldsymbol{\theta} \mathbf{q} - \kappa(\boldsymbol{\theta})] = \sum_{i=1}^r q_i \log \frac{q_i}{p_i} = H(\mathbf{q} \parallel \mathbf{p}) \quad (12)$$

ya que la derivada $\partial[\boldsymbol{\theta} \mathbf{q} - \kappa(\boldsymbol{\theta})]/\partial \theta_i = q_i - p_i e^{\theta_i} e^{-\kappa(\boldsymbol{\theta})}$ se anula para $e^{\theta_i} = e^{\kappa(\boldsymbol{\theta})} q_i / p_i$, lo cual da el valor indicado al sustituir en $\boldsymbol{\theta} \mathbf{q} - \kappa(\boldsymbol{\theta})$. La afirmación (11) es entonces consecuencia del Teorema de Varadhan ⁽⁷⁾.

Cuando A es cerrado, como Δ es compacto, existe una distribución $\mathbf{q}^* \in A$ que es la de mínima divergencia con $\mathbf{p}$. Entonces, la tasa de Cramér para la probabilidad de que la distribución empírica $\bar{\mathbf{Y}}_n$ pertenezca a A es $H(\mathbf{q}^* \parallel \mathbf{p})$.

2.2. El caso general

El enunciado del Teorema de Sanov, que se ha expuesto en la sección anterior, se refiere a las distribuciones empíricas $\bar{\mathbf{Y}}_n(a_i)$ obtenidas al componer un mensaje $\boldsymbol{\omega}$, eligiendo cada componente independientemente y con distribución $\mathbf{p}$. Pero la distribución empírica puede definirse en cualquier caso. Concretamente, si $X_1, \dots, X_n$ son variables aleatorias con valores en cualquier espacio medible $(E, \mathcal{E})$, la **distribución empírica** asociada es

$$\bar{\mathbf{Y}}_n(B) = \frac{1}{n} \sum_{i=1}^n \mathbf{I}_B(X_i) \quad \forall B \in \mathcal{E} \quad (13)$$

que expresa la frecuencia con la que figuran entre $X_1, \dots, X_n$ valores de B .

Dicha distribución empírica pertenece al espacio $\mathcal{P}(E)$ de las distribuciones de probabilidad en $(E, \mathcal{E})$. Sin embargo, a diferencia de la sección anterior en que Δ tenía dimensión r , cuando E no es finito $\mathcal{P}(E)$ es un espacio de dimensión infinita. No obstante, si E es un espacio métrico, $\mathcal{P}(E)$ puede considerarse como espacio métrico, con la métrica de Prohorov:

$$\rho(P, Q) = \inf\{\varepsilon > 0 : P(A) \leq Q(\bigcup_{y \in A} B(y, \varepsilon)) + \varepsilon \quad \forall A \in \mathcal{E}\}$$

que induce en $\mathcal{P}(E)$ la convergencia débil, $P_n \Rightarrow P$. Ésta se define por la convergencia $\int_E g dP_n \rightarrow \int_E g dP$ para cualquier $g : E \mapsto \mathbb{R}$ continua y acotada o, equivalentemente, por $P_n(A) \rightarrow P(A)$ para todo $A \in \mathcal{E}$ con $P(\partial A) = 0$, donde

⁶ Teorema 1 en *Grandes desviaciones de las sumas de v.a.i.i.d.*, generalizado al comienzo de la sección 3 para conjuntos convexos en $\mathbb{R}^d$.

⁷ Teorema 9 en *Grandes desviaciones de las sumas de v.a.i.i.d.* Una demostración del teorema de Sanov discreto que no hace uso de la teoría de grandes desviaciones puede verse en el Capítulo 11 de Cover, T.M. – Thomas, J.A. (2006): *Elements of information Theory*. John Wiley.

$\partial A = \bar{A} - A^\circ$. Hay que señalar que $\mathcal{P}(E)$ hereda las propiedades de E : es compacto si E es compacto, separable si lo es E y completo si E lo es ⁽⁸⁾.

Lo más habitual es considerar que $(X_1, \dots, X_n)$ es una muestra aleatoria simple de cierta distribución P ; es decir que son variables aleatorias (con valores en E) independientes e igualmente distribuidas con distribución P . En tal caso, según la ley de los grandes números, $\bar{Y}_n(B)$ converge casi seguro hacia $P(B)$ cuando $n \rightarrow \infty$, pero el conjunto de probabilidad cero en que la convergencia falla podría depender de $B \in \mathcal{E}$ (que no es numerable). Por eso tiene sentido probar:

Teorema 10 (Varadarahan) *Si E es un espacio métrico separable y $\{X_i\}$ son independientes y con distribución común P , con probabilidad 1 se cumple $\bar{Y}_n \Rightarrow P$.*

Es casi una generalización del Teorema de Glivenko–Cantelli que, para el caso $E = \mathbb{R}$, asegura que, con probabilidad uno, la distribución muestral $F_n^*(x)$ converge uniformemente a la distribución poblacional F ⁽⁹⁾.

A partir de aquí, aún conservando la máxima generalidad de los enunciados, las demostraciones se harán considerando el caso $E = \mathbb{R}^d$, para facilitar la obtención de resultados como los siguientes ⁽¹⁰⁾:

Lema 11 *Existe un homeomorfismo (biyectivo y bicontinuo) W de $\mathbb{R}^d$ sobre un abierto de la esfera S_d , de radio 1, en $d + 1$ dimensiones. Obviamente S_d es un compacto con la topología de $\mathbb{R}^{d+1}$.*

$\therefore$ La *proyección estereográfica* W hace corresponder a cada punto $x \in \mathbb{R}^d$ la intersección de S_d con la recta que une x con el polo norte $N = (0, \dots, 0, 1) \in S_d$. Evidentemente, W es una biyección entre $\mathbb{R}^d$ y el abierto $S_d - \{N\}$ y es continua y con inversa continua. $\square$

Se representará por X'_i la imagen de X_i mediante W , P' su distribución en S_d y $\bar{Y}'_n = W(\bar{Y}_n)$. Cualquier otra distribución $Q \in \mathcal{P}(E)$ tiene su transformada $Q' \in \mathcal{P}(S_d)$, mediante la transformación W .

Lema 12 *El espacio $C(S_d)$ de funciones continuas de S_d en $\mathbb{R}$, con la norma $\|f\| = \sup_{x \in S_d} |f(x)|$, es separable: hay una sucesión $\mathcal{D} = \{f_k\}_{k \in \mathbb{N}} \in C(S_d)$ que es densa en $C(S_d)$.*

$\therefore$ Se trata de una consecuencia del Teorema de Weierstrass ⁽¹¹⁾ que permite aproximar uniformemente cualquier función continua en el compacto $S_d \subset \mathbb{R}^{d+1}$ mediante polinomios de coeficientes racionales (que forman un conjunto numerable). $\square$

$\therefore$ Para probar el teorema 10 (en el caso $E = \mathbb{R}^d$) basta observar que, según la ley de los grandes números, para cualquier $f \in C(S_d)$, se cumple

$$\int_E f d\bar{Y}'_n = \frac{1}{n} \sum_{i=1}^n f(X'_i) \rightarrow \int_E f dP' \quad \text{casi seguro}$$

⁸ Véase el documento *El espacio de probabilidades y la convergencia débil*.

⁹ Véase *Principios de Inferencia*, §2.3.

¹⁰ La generalización necesaria para considerar cualquier E métrico, completo y separable, puede verse en Kechris, A.S. (1995): *Classical Descriptive Set Theory*. Springer–Verlag. §4.C, o también en Dudley, R.M. (2004): *Real Analysis and Probability*. Cambridge University Press.

¹¹ Véase Dudley, R.M. (2004): *Real Analysis and Probability*. Cambridge University Press, pág. 54.

y el suceso $\{\int_E f d\bar{Y}'_n \rightarrow \int_E f dP' \forall f \in \mathcal{D}\}$ tiene probabilidad 1 (ya que $\mathcal{D}$ es numerable). Ahora bien en tal suceso, para cualquier $g \in C(S_d)$, si $f \in \mathcal{D}$ es tal que $\|g - f\| < \varepsilon$, será

$$\left| \int_E g dP' - \lim_n \int_E g d\bar{Y}'_n \right| \leq \left| \int_E f dP' - \lim_n \int_E f d\bar{Y}'_n \right| + 2\varepsilon \leq 3\varepsilon$$

si n es grande; es decir que $\int_E g d\bar{Y}'_n \rightarrow \int_E g dP' \forall g \in C(S_d)$, o bien $\bar{Y}'_n \Rightarrow P'$. Ello implica que $\bar{Y}_n \Rightarrow P$ puesto que W^{-1} es continua ⁽¹²⁾. $\square$

El objetivo fundamental ahora es establecer que las variables aleatorias $\{\bar{Y}_n\}$ con valores en $\mathcal{P}(E)$ cumplen el P.G.D., pero hay algunas consideraciones previas que son necesarias. En primer lugar,

Lema 13 Si $Q_1, Q_2 \in \mathcal{P}(S_d)$ cumplen $\int_E f dQ_1 = \int_E f dQ_2 \forall f \in \mathcal{D}$, es $Q_1 \equiv Q_2$. Por tanto, la aplicación $G : \mathcal{P}(S_d) \mapsto \mathbb{R}^N$ definida por

$$G(Q) = \left[\int_{S_d} f_1 dQ, \dots, \int_{S_d} f_k dQ, \dots \right]$$

(donde $\{f_k\} = \mathcal{D}$) es inyectiva y también continua.

∴ Por supuesto, de $\int_{S_d} f dQ_1 = \int_{S_d} f dQ_2$ para toda $f \in \mathcal{D}$, se infiere que lo mismo se cumple para toda $f \in C(S_d)$, puesto que se puede aproximar uniformemente f por funciones en $\mathcal{D}$. Las medidas de probabilidad $Q \in \mathcal{P}(S_d)$ son regulares ⁽¹³⁾, lo cual significa que $Q(B) = \sup\{Q(C) : C \text{ cerrado}\}$ para todo subconjunto de Borel B de S_d . Por tanto, Q_1 y Q_2 coinciden si atribuyen la misma medida a todos los cerrados. Ahora bien, cualquiera que sea el subconjunto cerrado $C \subset S_d$, la función continua $g_k(x) = \max\{1 - kd(x, C), 0\}$ vale 1 en C , 0 si $x \notin A_k = \{d(x, C) < 1/k\}$ y toma un valor intermedio en $A_k - C$. Así pues

$$Q_1(C) \leq \int_E g_k dQ_1 = \int_E g_k dQ_2 \leq Q_2(A_k)$$

y, cuando $k \rightarrow \infty$, $A_k \downarrow C$ de modo que $Q_1(C) \leq Q_2(C)$. La desigualdad contraria, $Q_2(C) \leq Q_1(C)$, resulta de manera simétrica.

La continuidad de G se sigue de la propia definición de la convergencia $Q_n \Rightarrow Q$ que se considera en $\mathcal{P}(S_d)$, mientras que $\mathbb{R}^\infty$ está dotado de la topología producto para la cual $\mathbf{x}_n \rightarrow \mathbf{x}$ si todas las componentes $x_n^i \rightarrow x^i$. $\square$

Cuando E no es finito, para $P, Q \in \mathcal{P}(E)$, la **entropía relativa** de Q respecto a P se define como

$$H(Q\|P) = E_Q \left[\log \frac{dQ}{dP} \right] = \int_E \log h dQ = \int_E h \log h dP \quad (14)$$

si Q es absolutamente continua respecto a P ($Q \ll P$) y $h = dQ/dP$ es la derivada de Radon–Nikodym de Q respecto a P ⁽¹⁴⁾. En caso de que Q no sea absolutamente continua respecto a P , se define $H(Q\|P) = \infty$.

¹² Véase *El espacio de Probabilidades y la convergencia débil*, Teorema 4.

¹³ Véase *Procesos Estocásticos*, §A.3.

¹⁴ O sea $Q(A) = \int_A h dP$. Véase *Procesos Estocásticos*, §A.6.

Siempre es $H(Q\|P) \geq \int_E (h-1) dP = Q(E) - 1 = 0$ ya que $x \log x > x - 1$ salvo para $x = 1$. La igualdad solo se produce cuando $h \equiv 1$, o sea si $Q = P$. Además $H(Q\|P)$ es convexa en Q , puesto que $x \log x$ es convexa.

Hay una relación de la entropía relativa con el funcional

$$\kappa(g) = \log E[e^{g(X)}] = \log \int_E e^g dP$$

definido para cualquier g en el conjunto $\bar{\mathcal{B}}$ de las funciones medibles y acotadas de E en $\mathbb{R}$, y su transformada de Legendre

$$\kappa^*(Q) = \sup_{g \in \bar{\mathcal{B}}} \left\{ \int_E g dQ - \kappa(g) \right\}$$

definida para $Q \in \mathcal{P}(E)$.

Lema 14 (Donsker–Varadhan) $\kappa^*(Q) = H(Q\|P)$.

$\because$ Si $Q \not\ll P$, hay un conjunto $A \in \mathcal{E}$ tal que $P(A) = 0$ y $Q(A) > 0$, entonces las funciones $g_n = n \mathbf{I}_A$ dan

$$\int_E g_n dQ - \log \int_E e^{g_n} dP = nQ(A) - \log \int_{A^c} dP = nQ(A) \rightarrow \infty$$

es decir $\kappa^*(Q) = \infty = H(Q\|P)$.

Para $Q \ll P$, existe $h = dQ/dP$ y, si $g = \log h$ es acotada, se tiene

$$\kappa^*(Q) \geq \int_E \log h dQ - \log \int_E h dP = H(Q\|P).$$

En caso de que g no esté acotada, tomando una sucesión $g_n \in \bar{\mathcal{B}}$ tal que $g_n \rightarrow g$ y $|g_n| \leq |g|$, es $\int_E e^{g_n} dP \rightarrow 1$ y $\int_E g_n dQ \rightarrow H(Q\|P)$; así que $\kappa^*(Q) \geq H(Q\|P)$.

Para establecer la desigualdad contraria, se puede elegir como g una función simple: $g = \sum_{i=1}^r c_i \mathbf{I}_{B_i}$, en la que pueden determinarse valores de c_i para hacer grande

$$\int_E g dQ - \kappa(g) = \sum_{i=1}^r c_i Q(B_i) - \log \sum_{i=1}^r e^{c_i} P(B_i) = \sum_{i=1}^r Q(B_i) \log \frac{Q(B_i)}{P(B_i)}$$

pues, igual que en (12), $\partial[\int_E g dQ - \kappa(g)]/\partial c_i = Q(B_i) - e^{c_i} P(B_i) e^{-\kappa(g)}$ se anula cuando $e^{c_i} = e^{\kappa(g)} Q(B_i)/P(B_i)$ y se obtiene el valor indicado.

Este último término es la entropía relativa de Q respecto a P cuando ambas se condicionan por la σ -álgebra $\mathcal{G}$ generada por $B_1, \dots, B_r$. Pero la derivada de Radon-Nikodym de Q respecto a P restringidas a $\mathcal{G}$ es $E[h|\mathcal{G}]$ y vale $Q(B_i)/P(B_i)$ en cada uno de los conjuntos B_i , así que el último término se expresa

$$E[E[h|\mathcal{G}] \log E[h|\mathcal{G}]] \leq E[E[h \log h|\mathcal{G}]] = E[h \log h] = H(Q\|P)$$

en virtud de la desigualdad de Jensen. El resultado se extiende a cualquier función g medible y acotada, considerando una sucesión g_n de funciones simples tales que $g_n \rightarrow g$ y $|g_n| \leq |g|$. $\square$

El lema siguiente requiere del Teorema de Lusin, sobre aproximación de funciones medibles por funciones continuas, que se expone en el Apéndice.

Lema 15 $\kappa^*(Q) = \sup_{g \in \bar{C}(E)} \left\{ \int_E g dQ - \kappa(g) \right\}$ siendo $\bar{C}(E)$ el conjunto de funciones continuas y acotadas de E en $\mathbb{R}$.

$\therefore$ De acuerdo con el Teorema de Lusin, para cada $g \in \bar{\mathcal{B}}$ y $\delta > 0$, existe un cerrado C , con $(Q + P)(C^c) < \delta$, y una función continua γ tal que $g = \gamma$ en C y $\|\gamma\| = \sup |\gamma| \leq \sup |g| = \|g\|$. Entonces

$$\begin{aligned} \int_E g dQ - \log \int_E e^g dP &= \int_E \gamma dQ + \int_{C^c} (g - \gamma) dQ - \log \left(\int_E e^\gamma dP + \int_{C^c} (e^g - e^\gamma) dP \right) \\ &\leq \int_E \gamma dQ - \log \int_E e^\gamma dP + K\delta \end{aligned}$$

donde K es una constante que sólo depende del tamaño de $g - \gamma$ y $e^g - e^\gamma$ en C^c . Basta hacer $\delta \downarrow 0$, para obtener $\kappa^*(Q) \leq \sup_{\gamma \in \bar{C}(E)} \left\{ \int_E \gamma dQ - \kappa(\gamma) \right\}$. $\square$

Teorema 16 (Sanov) Sea E un espacio métrico, completo y separable, y $\{X_i\}$ variables aleatorias, con valores en E , independientes y con distribución común $P \in \mathcal{P}(E)$, las distribuciones empíricas $\{\bar{Y}_n\}$ verifican el P.G.D. con tasa compacta $J(Q) = H(Q\|P)$.

$\therefore$ La prueba (con $E = \mathbb{R}^d$) considera la sucesión $\mathcal{D} = \{f_k\}$ densa en $C(S_d)$.

Para cualquier $k \in \mathbb{N}$, los vectores $\mathbf{V}^k(X'_i) = [f_1(X'_i), \dots, f_k(X'_i)] \in \mathbb{R}^k$ son independientes y tienen la misma distribución para los diversos i ; además, ya que las componentes de $\mathbf{V}^k(X'_1)$ están acotadas, es $E[e^{\boldsymbol{\theta} \mathbf{V}^k(X'_1)}] < \infty \forall \boldsymbol{\theta} \in \mathbb{R}^k$. El Teorema de Varadhan ⁽¹⁵⁾ garantiza entonces que

$$\bar{\mathbf{V}}_n^k = \left[\frac{1}{n} \sum_{i=1}^n f_1(X'_i), \dots, \frac{1}{n} \sum_{i=1}^n f_k(X'_i) \right] = \left[\int_E f_1 d\bar{Y}'_n, \dots, \int_E f_k d\bar{Y}'_n \right]$$

cumple el P.G.D. con tasa compacta $I_k(\mathbf{a}) = \sup_{\boldsymbol{\theta} \in \mathbb{R}^k} \{ \boldsymbol{\theta} \mathbf{a} - \log E[e^{\boldsymbol{\theta} \mathbf{V}^k(X'_1)}] \}$ definida para $\mathbf{a} \in \mathbb{R}^k$.

Nótese que el resultado para $\bar{\mathbf{V}}_n^k$ contiene la misma conclusión para $\bar{\mathbf{V}}_n^j$ si $j \leq k$; además, según la Proposición 4 aplicada a la proyección de $\mathbb{R}^k$ en $\mathbb{R}^j$, se verifica $I_j(\mathbf{b}) = \inf \{ I_k(\mathbf{a}) : \mathbf{a}^j = \mathbf{b} \}$, donde $\mathbf{a}^j$ contiene las j primeras componentes de $\mathbf{a}$. Por consiguiente, para toda sucesión $\mathbf{a} \in \mathbb{R}^\infty$, es $I_j(\mathbf{a}^j) \leq I_k(\mathbf{a}^k)$, es decir que $I_k(\mathbf{a}^k) \uparrow I(\mathbf{a}) = \sup_k I_k(\mathbf{a}^k)$.

El propósito inicial es ver que $\bar{\mathbf{V}}_n^\infty = \left[\int_E f_1 d\bar{Y}'_n, \dots, \int_E f_k d\bar{Y}'_n, \dots \right] \in \mathbb{R}^\infty$ cumple el P.G.D. con tasa compacta $I(\mathbf{a})$.

(1) El conjunto $\{I(\mathbf{a}) \leq c\} = \{I_k(\mathbf{a}^k) \leq c \forall k \in \mathbb{N}\}$ es compacto. En efecto, si $\{\mathbf{a}_i\}$ es cualquier sucesión en $\{I(\mathbf{a}) \leq c\}$, será $I_k(\mathbf{a}_i^k) \leq c \forall k$ y, como $\{I_k(\mathbf{a}) \leq c\}$ es compacto, $\{\mathbf{a}_{i_1(m)}^k\}$ convergerá a $\mathbf{b}^k \in \{I_k(\mathbf{a}) \leq c\}$ para cierta subsucesión $\{i_1(m)\}$; ésta tendrá a su vez una subsucesión $\{i_2(m)\}$ con $\mathbf{a}_{i_2(m)}^{2k} \rightarrow \mathbf{b}^{2k} \in \{I_{2k}(\mathbf{a}) \leq c\}$ (naturalmente $\mathbf{b}^k$ son las k primeras componentes de $\mathbf{b}^{2k}$) y así sucesivamente: $\mathbf{a}_{i_r(m)}^{rk} \rightarrow \mathbf{b}^{rk} \in \{I_{rk}(\mathbf{a}) \leq c\}$ siendo $\{i_r(m)\} \subset \{i_{r-1}(m)\}$. A lo largo de la sucesión diagonal $\{i^*(m) = i_m(m)\}$ se verifica $\mathbf{a}_{i^*(m)}^k \rightarrow \mathbf{b}^k \in \{I_k(\mathbf{a}) \leq c\} \forall k$, de manera que $\mathbf{a}_{i^*(m)} \rightarrow \mathbf{b} \in \{I(\mathbf{a}) \leq c\}$. Así pues, $I(\mathbf{a})$ es una tasa compacta en $\mathbb{R}^\infty$.

(2) Para cualquier cerrado $A \subset \mathbb{R}^\infty$, sea $A_k = \{\mathbf{a}^k : \mathbf{a} \in A\} = \pi_k A$ la proyección de A en $\mathbb{R}^k$; A_k no es necesariamente cerrado, pero se cumple $A = \{\mathbf{a} : \mathbf{a}^k \in \bar{A}_k \forall k\}$.

¹⁵ Teorema 9 en *Grandes desviaciones de las sumas de v.a.i.i.d.*

En efecto, si $\mathbf{a} \in A$, $\mathbf{a}^k \in A_k \subset \overline{A_k} \forall k$. Recuérdese que la colección de conjuntos $\{\pi_k^{-1}U : k \in \mathbb{N}, U \text{ abierto en } \mathbb{R}^k\}$ es la base de la topología de $\mathbb{R}^\infty$; así que, si $\mathbf{a} \in A^c$, existe $k \in \mathbb{N}$ y un abierto $U \subset \mathbb{R}^k$ tal que $\mathbf{a}^k \in U \subset A_k^c$, con lo cual $\mathbf{a}^k \notin \overline{A_k}$.

Ahora, repitiendo el argumento (1), $A \cap \{I(\mathbf{a}) \leq c\} = \{\mathbf{a}^k \in \overline{A_k}, I_k(\mathbf{a}^k) \leq c \forall k\}$ no puede ser vacío, a no ser que $\overline{A_k} \cap \{I_k(\mathbf{a}) \leq c\}$ sea vacío para algún k . Es decir que, si $I(A) > c$, será $I_k(\overline{A_k}) \geq c$ para cierto k_0 . Por consiguiente

$$\limsup_n \frac{1}{n} \log P\{\bar{V}_n^\infty \in A\} \leq \limsup_n \frac{1}{n} \log P\{\bar{V}_n^{k_0} \in A_{k_0}\} \leq -I_{k_0}(\overline{A_{k_0}}) \leq -c$$

y, puesto que la conclusión vale para cualquier $c < I(A)$, se obtiene (4) para $\bar{V}_n^\infty$.

(3) Para cualquier abierto $A \subset \mathbb{R}^\infty$, si $\mathbf{a} \in A$, existe $k \in \mathbb{N}$ y un abierto $U \subset \mathbb{R}^k$ tal que $\mathbf{a}^k \in U \subset A^k$. Por tanto

$$\liminf_n \frac{1}{n} \log P\{\bar{V}_n^\infty \in A\} \geq \liminf_n \frac{1}{n} \log P\{\bar{V}_n^k \in U\} \geq -I_k(U) \geq -I_k(\mathbf{a}^k) \geq -I(\mathbf{a})$$

y (5) se obtiene observando que $\mathbf{a} \in A$ es arbitrario.

Una vez sabido que $\bar{V}_n^\infty$ cumple P.G.D. con tasa compacta $I(\mathbf{a})$, como el espacio $\mathcal{P}(S_d)$ es compacto, la sucesión $\{\bar{Y}_n'\}$ es exponencialmente acotada. Además, en virtud del Lema 13, la aplicación $G : \mathcal{P}(S_d) \mapsto \mathbb{R}^\infty$ es continua e inyectiva. Como $\bar{V}_n^\infty = G(\bar{Y}_n')$, la Proposición 6 asegura que $\{\bar{Y}_n'\}$ cumple el P.G.D. en $\mathcal{P}(S_d)$ con tasa compacta: $J(Q) = I(G(Q))$. Dicha tasa se puede expresar

$$\begin{aligned} J(Q) &= I(G(Q)) = \sup_k \sup_{\theta \in \mathbb{R}^k} \left\{ \sum_{r=1}^k \theta_r \int_{S_d} f_r dQ - \log \int_{S_d} \exp \left[\sum_{r=1}^k \theta_r f_r \right] dP \right\} \\ &= \sup_{g \in L} \left\{ \int_{S_d} g dQ - \kappa(g) \right\} = \sup_{g \in \bar{C}(S_d)} \left\{ \int_{S_d} g dQ - \kappa(g) \right\} \end{aligned}$$

donde L es el conjunto de combinaciones lineales: $g = \sum_{r=1}^k \theta_r f_r$ que es, desde luego, denso en $\bar{C}(S_d)$. De acuerdo con los Lemas 14 y 15, resulta $J(Q) = H(Q\|P)$. En principio, $H(Q\|P)$ ha de calcularse en S_d , pero el cambio de variable W en la definición (14) muestra que $H(Q'\|P') = H(Q\|P)$.

El lema siguiente prueba que $\{\bar{Y}_n\}$ es exponencialmente acotada en $\mathcal{P}(E)$, así que, aplicando nuevamente la Proposición 6 a $\bar{Y}_n' = W(\bar{Y}_n)$, resulta que $\bar{Y}_n$ verifica el P.G.D. con tasa compacta $H(Q\|P)$. $\square$

Lema 17 $\{\bar{Y}_n\}$ está exponencialmente acotada como sucesión de $\mathcal{P}(E)$.

$\therefore$ Para cualquier $A \in \mathcal{E}$ sea $p = P\{X_i \in A\} \in (0, 1)$ y recuérdese que, según el ejemplo 5 en *Grandes desviaciones de las sumas de v.a.i.i.d.*, es

$$\sup_n \frac{1}{n} \log P\{\bar{Y}_n(A) > a\} \leq -a \log \frac{a}{p} - (1-a) \log \frac{1-a}{1-p}.$$

Para a fijo, la cota del segundo miembro tiende a $-\infty$ cuando $p \rightarrow 0$; así que, tomando $a = 1/2^j$, se puede elegir p_j suficientemente pequeño para que la cota sea inferior a $-jr$ para cualquier $r > 0$ dado. Sea $K_j \subset E$ un compacto con $P\{X_i \in K_j^c\} < p_j$, entonces

$$P\{\bar{Y}_n(K_j^c) > 1/2^j\} \leq e^{-n jr} \quad \forall n, j \quad \text{y} \quad P\left(\bigcup_{j=1}^\infty \{\bar{Y}_n(K_j^c) > 1/2^j\}\right) \leq \frac{e^{-nr}}{1 - e^{-nr}}$$

con lo cual

$$\limsup_n \frac{1}{n} \log P \left(\bigcup_{j=1}^{\infty} \{ \bar{Y}_n(K_j^c) > 1/2^j \} \right) \leq -r.$$

Si $\mathcal{K} = \{Q \in \mathcal{P}(E) : Q(K_j^c) \leq 1/2^j \forall j\}$ se tiene

$$\limsup_n \frac{1}{n} \log P \{ \bar{Y}_n \notin \mathcal{K} \} \leq -r;$$

ésta es la condición que debe cumplir $\{\bar{Y}_n\}$ para ser exponencialmente acotada, supuesto que $\mathcal{K}$ es un compacto de $\mathcal{P}(E)$ (con la métrica de Prohorov). Y, efectivamente, $\mathcal{K}$ es una familia de distribuciones de $\mathcal{P}(E)$ uniformemente acotada, en el sentido de que, para todo $\varepsilon > 0$ existe un compacto $K \subset E$ tal que $Q(K^c) < \varepsilon \forall Q \in \mathcal{K}$; el Teorema de Prohorov garantiza entonces que $\mathcal{K}$ es un subconjunto relativamente compacto de $\mathcal{P}(E)$ ⁽¹⁶⁾. Más aún, $\mathcal{K}$ es cerrado porque, si $Q_n \Rightarrow Q$ y $Q_n \in \mathcal{K} \forall n$, se tiene $Q(K_j^c) \leq \liminf_n Q_n(K_j^c) \leq 1/2^j \forall j$ ⁽¹⁷⁾; luego $Q \in \mathcal{K}$. $\square$

El Teorema de Sanov tiene su extensión a las distribuciones empíricas de varias dimensiones; por ejemplo,

$$\bar{Y}_n^{(2)}(B) = \frac{1}{n} \sum_{i=1}^n \mathbf{I}_B(X_i, X_{i+1}) \quad (\text{con } X_{n+1} = X_1)$$

indica la frecuencia con la que los pares (X_i, X_{i+1}) pertenecen al conjunto $B \in \mathcal{E} \otimes \mathcal{E}$. Se trata de distribuciones pertenecientes a $\mathcal{P}(E \times E)$ cuyas marginales coinciden ambas con $\bar{Y}_n$. Suponiendo que $\{X_i\}$ son independientes y con distribución común P , se cumple $\bar{Y}_n^{(2)} \Rightarrow P \times P$ y la sucesión $\{\bar{Y}_n^{(2)}\}$ verifica el P.G.D. con tasa compacta $J^{(2)}(Q) = H(Q \| Q_1 \times P)$ si Q tiene ambas marginales iguales a Q_1 , mientras que $J^{(2)}(Q) = \infty$ si Q tiene marginales distintas.

Análogamente

$$\bar{Y}_n^{(3)}(B) = \frac{1}{n} \sum_{i=1}^n \mathbf{I}_B(X_i, X_{i+1}, X_{i+2}) \quad (\text{con } X_{n+1} = X_1, X_{n+2} = X_2)$$

tiene marginales bidimensionales que coinciden todas con $\bar{Y}_n^{(2)}$. Supuesto que $\{X_i\}$ son independientes y con distribución común P , $\bar{Y}_n^{(3)} \Rightarrow P \times P \times P$ y $\{\bar{Y}_n^{(3)}\}$ cumple el P.G.D. con tasa compacta $J^{(3)}(Q) = H(Q \| Q_2 \times P)$ si las marginales bidimensionales de Q son todas iguales a Q_2 y $J^{(3)}(Q) = \infty$ en caso contrario.

Como sumario de los últimos resultados, cuando $E = \mathbb{R}$ la distribución empírica $\{\bar{Y}_n\}$ puede representarse en forma de histograma con una adecuada partición de $\mathbb{R}$. Si la distribución P de los elementos de la muestra tiene densidad h (o sea $P(B) = \int_B h(x) dx$), el Teorema 10 afirma que el histograma tiende a ser semejante a h cuando el tamaño muestral crece. Lo que el Teorema de Sanov 16 añade es que la probabilidad de que el histograma se parezca a la densidad de otra distribución Q , distinta de P , decrece como $\exp\{-nH(Q \| P)\}$.

¹⁶ Véase el Teorema 11 en *El espacio de probabilidades y la Convergencia débil*.

¹⁷ Véase el Teorema 2 en *El espacio de probabilidades y la Convergencia débil*.

3. Aplicaciones a la Física Estadística

3.1. Gases ideales

Para ilustrar la aplicación de los resultados sobre grandes desviaciones a la Mecánica Estadística, los modelos más simples consideran una situación próxima a la de la sección 2.1. Concretamente, un gas ideal se compone de un gran número, n , de partículas, cada una de las cuales puede tener una energía dentro de un conjunto finito $\Gamma = \{a_1 < a_2 < \dots < a_r\} \subset \mathbb{R}$, de modo que el “microestado” del gas se describe por el vector $\omega = (\omega_1, \dots, \omega_n) \in \Gamma^n$ que indica el nivel de energía de cada partícula. Se supone que las componentes ω_j son independientes y tienen una cierta distribución $\mathbf{p} = (p_1, \dots, p_r) \in \Delta$; ello da lugar a una distribución P sobre $\Omega = \Gamma^n$ que asigna al microestado ω probabilidad $P(\omega) = \prod_{j=1}^r p_j^{n_j}$ donde n_j es el número de partículas que tienen energía a_j .

A priori, la energía media de cada partícula es $\bar{a} = \sum_{j=1}^r p_j a_j$ y, en el microestado ω , la energía total del sistema es $S_n = \sum_{i=1}^n \omega_i = \sum_{j=1}^r n_j a_j$. Naturalmente, nunca es posible conocer el microestado en que se encuentra el gas, pero sí puede medirse, con cierta precisión, la energía total y deducir la energía media, S_n/n , de cada partícula en dicho microestado.

Supongamos que se ha medido una energía media $S_n/n \in [a - \delta, a]$ con $a_1 < a - \delta < a < \bar{a}$; interesa entonces conocer la distribución del reparto de energías, condicionado por el dato $S_n/n \in [a - \delta, a]$. El resultado siguiente proporciona la solución.

Teorema 18 (A) Para cada $j = 1, \dots, r$, sea

$$p_j(\beta) = \frac{p_j e^{-\beta a_j}}{\sum_{j=1}^r p_j e^{-\beta a_j}} \quad (15)$$

donde $\beta = \beta(a)$ es la única solución de la ecuación $\sum_{j=1}^r p_j(\beta) a_j = a$. La distribución empírica $\bar{\mathbf{Y}}_n \in \Delta$ (que da la frecuencia n_j/n de partículas con cada nivel de energía a_j) verifica

$$\lim_n P\{\|\bar{\mathbf{Y}}_n - \mathbf{p}(\beta)\| \leq \varepsilon \mid S_n/n \in [a - \delta, a]\} = 1.$$

(B) Para cualquier $f : \Delta \mapsto \mathbb{R}$ continua, es

$$E[f(\bar{\mathbf{Y}}_n) \mid S_n/n \in [a - \delta, a]] = f(\mathbf{p}(\beta)). \quad (16)$$

(C) Para cada $j = 1, \dots, r$ e $i = 1, \dots, n$, es

$$\lim_n P\{\omega_i = a_j \mid S_n/n \in [a - \delta, a]\} = p_j(\beta). \quad (17)$$

∴ (A) La función

$$c(x) = \log \sum_{j=1}^r p_j e^{a_j x} \quad \text{con derivada} \quad c'(x) = \frac{\sum_{j=1}^r p_j a_j e^{a_j x}}{\sum_{j=1}^r p_j e^{a_j x}}$$

cumple $c'(0) = \bar{a}$, $\lim_{x \rightarrow -\infty} c'(x) = a_1$, $\lim_{x \rightarrow \infty} c'(x) = a_r$ y $c''(x) > 0$ (aplicando la desigualdad de Cauchy-Schwarz). Por consiguiente, existe un único $\beta = \beta(a)$ tal que $c'(-\beta) = a$ con $\beta > 0$ pues $a < \bar{a} = c'(0)$ y c' es creciente (sería $\beta < 0$ si fuese $a > \bar{a}$).

Sea $\Delta(a) = \{\mathbf{q} \in \Delta : \sum_{j=1}^r q_j a_j \in [a - \delta, a]\}$; como $a = c'(-\beta) = \sum_{j=1}^r p_j(\beta) a_j$, es $\mathbf{p}(\beta) \in \Delta(a)$ y, por otra parte, $\{S_n/n \in [a - \delta, a]\} = \{\bar{\mathbf{Y}}_n \in \Delta(a)\}$ puesto que $S_n/n = \sum_{j=1}^r a_j \bar{Y}_n(a_j)$. Así pues, según el Teorema 9,

$$\begin{aligned} P\{\bar{\mathbf{Y}}_n \in B(\mathbf{p}(\beta), \varepsilon) \mid S_n/n \in [a - \delta, a]\} &= P\{\bar{\mathbf{Y}}_n \in B(\mathbf{p}(\beta), \varepsilon) \mid \bar{\mathbf{Y}}_n \in \Delta(a)\} \\ &= \frac{P\{\bar{\mathbf{Y}}_n \in B(\mathbf{p}(\beta), \varepsilon) \cap \Delta(a)\}}{P\{\bar{\mathbf{Y}}_n \in \Delta(a)\}} \\ &\sim \exp\{-n[I(B(\mathbf{p}(\beta), \varepsilon) \cap \Delta(a)) - I(\Delta(a))]\} \end{aligned}$$

donde $I(\mathbf{q}) = H(\mathbf{q} \parallel \mathbf{p})$ e $I(A) = \inf_{\mathbf{q} \in A} I(\mathbf{q})$. El resultado se sigue entonces del

Lema 19 $I(\mathbf{q})$ alcanza su mínimo sobre $\Delta(a)$ para $\mathbf{q} = \mathbf{p}(\beta)$.

En efecto, $p_j(\beta)/p_j = e^{-\beta a_j} e^{-c(-\beta)}$, con lo cual

$$\begin{aligned} I(\mathbf{q}) &= \sum_{j=1}^r q_j \log \frac{q_j}{p_j} = \sum_{j=1}^r q_j \log \frac{q_j}{p_j(\beta)} + \sum_{j=1}^r q_j \log \frac{p_j(\beta)}{p_j} \\ &= H(\mathbf{q} \parallel \mathbf{p}(\beta)) - \beta \sum_{j=1}^r q_j a_j - c(-\beta). \end{aligned}$$

En particular $I(\mathbf{p}(\beta)) = -\beta a - c(-\beta)$; luego, como $H(\mathbf{q} \parallel \mathbf{p}(\beta)) \geq 0$ con igualdad solo para $\mathbf{q} = \mathbf{p}(\beta)$, si $\mathbf{q} \in \Delta(a)$ y $\mathbf{q} \neq \mathbf{p}(\beta)$, resulta

$$I(\mathbf{q}) > -\beta \sum_{j=1}^r q_j a_j - c(-\beta) \geq -\beta a - c(-\beta) = I(\mathbf{p}(\beta)).$$

(B) Según (A), con la distribución condicionada por $S_n/n \in [a - \delta, a]$, es $\bar{\mathbf{Y}}_n \rightarrow \mathbf{p}(\beta)$ casi seguro; luego $f(\bar{\mathbf{Y}}_n) \rightarrow f(\mathbf{p}(\beta))$ casi seguro y se obtiene (16), puesto que f está acotada en el compacto Δ .

(C) Cualquier $\varphi : \Gamma \mapsto \mathbb{R}$ tiene asociada la función continua $f(\mathbf{q}) = \sum_{j=1}^r q_j \varphi(a_j)$ que cumple

$$f(\bar{\mathbf{Y}}_n) = \sum_{j=1}^r \bar{Y}_n(j) \varphi(a_j) = \frac{1}{n} \sum_{i=1}^n \varphi(\omega_i);$$

luego, de acuerdo con (B), es

$$\begin{aligned} \lim_n E[\varphi(\omega_i) \mid S_n/n \in [a - \delta, a]] &= \lim_n \frac{1}{n} \sum_{i=1}^n E[\varphi(\omega_i) \mid S_n/n \in [a - \delta, a]] \\ &= \lim_n E[f(\bar{\mathbf{Y}}_n) \mid S_n/n \in [a - \delta, a]] = f(\mathbf{p}(\beta)) = \sum_{j=1}^r p_j(\beta) \varphi(a_j) \end{aligned}$$

y, tomando $\varphi = \mathbf{I}_{\{a_j\}}$, resulta

$$\lim_n P\{\omega_i = a_j \mid S_n/n \in [a - \delta, a]\} = p_j(\beta). \quad \square$$

Un resultado similar vale para el caso en que la medida de la energía media informe de que $S_n/n \in [a, a + \delta]$ con $\bar{a} < a < a + \delta < a_r$; la única diferencia es que, en tal caso, es $\beta < 0$.

Mediante la extensión del Teorema de Sanov a distribuciones empíricas multidimensionales, la conclusión (17) puede generalizarse en la forma

$$\lim_n P\{\omega_{i_1} = a_{j_1}, \omega_{i_2} = a_{j_2}, \dots, \omega_{i_k} = a_{j_k} | S_n/n \in [a - \delta, a]\} = \prod_{r=1}^k p_{j_r}(\beta)$$

que indica que, condicionado por $S_n/n \in [a - \delta, a]$, el microestado tiene sus componentes independientes y con distribución común $\mathbf{p}(\beta)$.

La distribución dada por (15) es la **distribución de Gibbs** ⁽¹⁸⁾, fundamental en Física Estadística. Depende del parámetro β , cuya inversa $T = 1/\beta$ se conoce como **temperatura** del gas. La ecuación $\sum_{j=1}^r p_j(\beta) a_j = a$ permite conocer la energía a contenida en el sistema cuando se mide la temperatura $T = 1/\beta$.

El resultado del Lema 19 se conoce como *Principio de la máxima entropía*: la única distribución $\mathbf{q}$ que minimiza $I(\mathbf{q})$, con la restricción $\mathbf{q} \in \Delta(a)$, es $\mathbf{p}(\beta)$, hacia la que converge $\bar{\mathbf{Y}}_n$ cuando $n \rightarrow \infty$, supuesto que $S_n/n \in [a - \delta, a]$. Normalmente, la distribución a priori $\mathbf{p}$ se supone uniforme sobre Γ y, en tal caso, según (10) el mínimo de $H(\mathbf{q} \parallel \mathbf{p})$ coincide con el máximo de $H(\mathbf{q})$.

3.2. Ferromagnetismo. Modelo de Curie-Weiss

Una pieza de hierro está constituida por átomos situados en los vértices de un retículo tridimensional ($\subset \mathbb{Z}^3$). En la magnetización de la pieza participan los electrones desemparejados de cada átomo (todos ellos de la capa $3d$) a través de su “spin” que solo puede tomar dos valores $+1$ o -1 . Si son n electrones, las diversas configuraciones o “microestados” posibles son los elementos $\omega = (\omega_1, \omega_2, \dots, \omega_n)$ pertenecientes al espacio $\Omega = \{-1, 1\}^n$.

A priori, todas las configuraciones tienen igual probabilidad $P(\omega) = 1/2^n$ y cada una proporciona a la pieza una energía total o Hamiltoniano

$$\mathcal{H}_n(\omega) = -\frac{1}{2n} \sum_{i,j=1}^n \omega_i \omega_j = -\frac{n}{2} \left(\frac{1}{n} \sum_{i=1}^n \omega_i \right)^2 = -\frac{n}{2} \left(\frac{S_n(\omega)}{n} \right)^2 \quad (18)$$

que indica que las parejas iguales ($\omega_i = \omega_j$) disminuyen $\mathcal{H}_n$, mientras que las parejas contrapuestas ($\omega_i = -\omega_j$) la aumentan. $S_n(\omega)/n = (1/n) \sum_{i=1}^n \omega_i$ es el “spin promedio” que toma valores en $[-1, 1]$ y describe el “macroestado” observable para medir la magnetización de la pieza. La proximidad de S_n/n a cero significa que los spines positivos y negativos se compensan y la pieza no tiene propiedades magnéticas. En cambio, un spin promedio próximo a ± 1 indica que predominan los spines de un mismo signo y la pieza está magnetizada.

Con una temperatura inversa $\beta > 0$, se asocia la distribución sobre Ω definida por

$$P_\beta(\omega) = e^{-\beta \mathcal{H}_n(\omega)} \frac{1}{Z_n(\beta)} P(\omega) \quad \text{donde} \quad Z_n(\beta) = \sum_{\omega} e^{-\beta \mathcal{H}_n(\omega)} P(\omega)$$

es la denominada *función de partición*. La distribución P_β describe la elección del microestado ω cuando la pieza puede magnetizarse a temperatura $1/\beta$, porque

¹⁸ Véase el documento *Introducción a la Física Estadística*.

asigna máxima probabilidad a los dos microestados $\omega_i = 1 \ \forall i$ y $\omega_i = -1 \ \forall i$, mientras que da menor probabilidad a ω cuanto más se diferencie de ± 1 el spin promedio $S_n(\omega)/n$. De hecho cuando $\beta \rightarrow \infty$ (la temperatura se acerca al cero absoluto), P_β se concentra en los dos microestados con $S_n/n = \pm 1$.

Sin embargo hay muchos más microestados que corresponden a un macroestado definido por un valor moderado de $|S_n|/n$ que microestados con un valor extremo de $|S_n|/n$. Así que interesa estudiar la distribución de S_n/n y comprobar que, cuando la temperatura $1/\beta$ aumenta, S_n/n se concentra alrededor de uno de dos valores simétricos $\pm m(\beta) \in [-1, 1]$.

En este sentido cabe observar que, respecto a P , en virtud del Teorema de Cramér, S_n/n verifica el P.G.D con función tasa

$$\psi(a) = \frac{1}{2} (1+a) \log(1+a) + \frac{1}{2} (1-a) \log(1-a) \quad a \in (-1, 1)$$

obtenida mediante un cálculo totalmente análogo al del ejemplo 5 en *Grandes desviaciones de las sumas de v.a.i.i.d.* (con $P\{X_i = 1\} = \frac{1}{2} = P\{X_i = -1\}$). Es decir $P\{S_n/n > a\} \sim e^{-n\psi(a)}$ si $a \in (0, 1)$.

Ahora puede probarse que también se verifica el P.G.D. para $P_\beta\{S_n/n \in dx\}$ haciendo uso de su equivalencia con el Principio de Laplace establecida en los teoremas 7 y 8. Para ello se abreviará $Y_n = S_n/n$ y se considera la función $g(x) = -\frac{1}{2}\beta x^2$ con $x \in [-1, 1]$, de manera que

$$\beta \mathcal{H}_n(\omega) = ng(S_n/n) \quad \text{y} \quad P_\beta(\omega) = e^{-ng(S_n/n(\omega))} \frac{1}{Z_n(\beta)} P(\omega).$$


Entonces, para cualquier función continua y acotada $f : [-1, 1] \mapsto \mathbb{R}$, es

$$\begin{aligned} \frac{1}{n} \log \sum_{\omega} e^{-nf(Y_n(\omega))} P_\beta(\omega) &= \frac{1}{n} \log \sum_{\omega} e^{-nf(Y_n(\omega))} e^{-ng(Y_n(\omega))} \frac{1}{Z_n(\beta)} P(\omega) \\ &= \frac{1}{n} \log \sum_{\omega} e^{-n(f+g)(Y_n(\omega))} P(\omega) - \frac{1}{n} \log Z_n(\beta) \\ &= \frac{1}{n} \log \sum_{\omega} e^{-n(f+g)(Y_n(\omega))} P(\omega) - \frac{1}{n} \log \sum_{\omega} e^{-ng(Y_n(\omega))} P(\omega) \\ &= -\inf_a \{f(a) + g(a) + \psi(a)\} + \inf_a \{g(a) + \psi(a)\} \end{aligned}$$

puesto que, respecto a P , Y_n cumple el Principio de Laplace con tasa $\psi(a)$. La conclusión es que, respecto a P_β , también se cumple el Principio de Laplace –y el P.G.D– con tasa

$$\psi_\beta(a) = g(a) + \psi(a) - \inf_a \{g(a) + \psi(a)\}$$

La siguiente gráfica muestra las curvas $\psi(a) + g(a)$ para $\beta \leq 1$ y $\beta > 1$.



Para $\beta \leq 1$, $g(a) + \psi(a) \geq 0$ se anula para $a = 0$, así que

$$\psi_\beta(a) = \psi(a) - \frac{1}{2}\beta a^2 \quad \text{y} \quad P_\beta\{S_n/n \in A\} \sim e^{-n\psi_\beta(a_0)}$$

para cualquier intervalo $A \subset (-1, 0) \cup (0, 1)$ donde a_0 es el extremo de A más próximo a 0. Desde luego ello implica que $S_n/n \xrightarrow{P_\beta} 0$ y la magnetización no se produce.

Para $\beta > 1$, $g(a) + \psi(a)$ alcanza un mínimo negativo en los valores $\pm m(\beta)$ (que solo pueden determinarse numéricamente). Luego

$$\psi_\beta(a) = \psi(a) + \psi(m(\beta)) - \frac{1}{2}\beta(a - m(\beta))^2 \quad \text{y} \quad P_\beta\{S_n/n \in A\} \sim e^{-n\psi_\beta(a_0)}$$

para cualquier intervalo $A \subset (-1, -m(\beta)) \cup (-m(\beta), m(\beta)) \cup (m(\beta), 1)$ donde a_0 es el extremo de A más próximo a $\pm m(\beta)$. Ahora solo se puede afirmar que la distribución bajo P_β de S_n/n converge a la distribución que toma los valores $\pm m(\beta)$ con probabilidades 1/2. Hay, por tanto, en este caso magnetización espontánea.

En Física estadística se dice que 0 y $\pm m(\beta)$ son los “macroestados” de equilibrio posibles según la temperatura β . También $\beta = 1$ se denomina la “temperatura crítica”, que delimita cuando se produce la magnetización.

La especificación (18) es característica del modelo de Curie-Weiss. El más popular y realista modelo de Ising incluye en la primera suma de (18) únicamente los pares electrónicos vecinos (con $|i-j| \leq 1$). Puede consultarse a este respecto [3, Capítulos IV y V], así como Dobrushin, R.L. – Shlosman, S.B. (1994): *Large and moderate deviations in the Ising Model*. Adv. Soviet Math. 20:91-219.

4. Teorema de Gärtner–Ellis

Es posible establecer el P.G.D. para sucesiones de variables aleatorias sin necesidad de suponer independencia ni igual distribución. Para ello se considera una sucesión de variables aleatorias $\{\mathbf{X}_n\}$ definidas en distintos espacios de probabilidad $(\Omega_n, \mathcal{F}_n, P_n)$, con valores en $\mathbb{R}^d$. Sea

$$\kappa_n(\boldsymbol{\theta}) = \frac{1}{v_n} \log E_n[e^{\boldsymbol{\theta} \mathbf{X}_n}] \quad \forall \boldsymbol{\theta} \in \mathbb{R}^d$$

donde $v_n \rightarrow \infty$. Se supone que

$$(H') \quad \kappa_n(\boldsymbol{\theta}) < \infty \quad \forall \boldsymbol{\theta} \in \mathbb{R}^d \quad \text{y existe} \quad \kappa(\boldsymbol{\theta}) = \lim_n \kappa_n(\boldsymbol{\theta}) < \infty \quad \forall \boldsymbol{\theta} \in \mathbb{R}^d.$$

La desigualdad de Hölder permite comprobar que $\kappa_n(\boldsymbol{\theta})$ son funciones convexas y, por tanto, también lo es $\kappa(\boldsymbol{\theta})$. Acerca de la transformada de Legendre

$$\kappa^*(\mathbf{a}) = \sup_{\boldsymbol{\theta} \in \mathbb{R}^d} \{\boldsymbol{\theta} \mathbf{a} - \kappa(\boldsymbol{\theta})\} \quad \forall \mathbf{a} \in \mathbb{R}^d$$

lo primero que puede probarse es que se trata de una *función tasa compacta* que es convexa y con $\kappa^*(\mathbb{R}^d) = 0$.

Lema 20 *Si se verifica (H') , $\kappa^*(\mathbf{a})$ es convexa y $\{\kappa^*(\mathbf{a}) \leq c\}$ es compacto $\forall c \in \mathbb{R}$. Además $\inf_{\mathbf{a} \in \mathbb{R}^d} \kappa^*(\mathbf{a}) = 0$ y $\kappa^*(\mathbf{a}) = 0$ si y solo si $\boldsymbol{\theta} \mathbf{a} \leq \kappa(\boldsymbol{\theta}) \quad \forall \boldsymbol{\theta} \in \mathbb{R}^d$.*

∴ La convexidad es inmediata: si $p + q = 1$ es

$$\kappa^*(p\mathbf{a}_1 + q\mathbf{a}_2) = \sup_{\boldsymbol{\theta}} \{p[\boldsymbol{\theta} \mathbf{a}_1 - \kappa(\boldsymbol{\theta})] + q[\boldsymbol{\theta} \mathbf{a}_2 - \kappa(\boldsymbol{\theta})]\} \leq p\kappa^*(\mathbf{a}_1) + q\kappa^*(\mathbf{a}_2).$$

Si $\mathbf{a}_n \rightarrow \mathbf{a}$, como $\kappa^*(\mathbf{a}_n) \geq \boldsymbol{\theta} \mathbf{a}_n - \kappa(\boldsymbol{\theta}) \quad \forall \boldsymbol{\theta} \in \mathbb{R}^d$, será

$$\liminf_n \kappa^*(\mathbf{a}_n) \geq \boldsymbol{\theta} \mathbf{a} - \kappa(\boldsymbol{\theta}) \quad \forall \boldsymbol{\theta} \quad \text{con lo cual} \quad \liminf_n \kappa^*(\mathbf{a}_n) \geq \boldsymbol{\theta} \mathbf{a} - \kappa(\boldsymbol{\theta})$$

y, puesto que ello es cierto para cualquier $\boldsymbol{\theta} \in \mathbb{R}^d$, es $\liminf_n \kappa^*(\mathbf{a}_n) \geq \kappa^*(\mathbf{a})$. Supuesto que $\kappa^*(\mathbf{a}_n) \leq c$ también $\kappa^*(\mathbf{a}) \leq c$; así que $\{\kappa^*(\mathbf{a}) \leq c\}$ es cerrado.

Ahora, como $\kappa(\boldsymbol{\theta}) + \kappa^*(\mathbf{a}) \geq \boldsymbol{\theta} \mathbf{a} \quad \forall \boldsymbol{\theta}, \mathbf{a} \in \mathbb{R}^d$, si $\mathbf{a} \in \{\kappa^*(\mathbf{a}) \leq c\}$ será

$$\boldsymbol{\theta} \mathbf{a} \leq \kappa(\boldsymbol{\theta}) + \kappa^*(\mathbf{a}) \leq \kappa(\boldsymbol{\theta}) + c \quad \text{de donde} \quad \|\mathbf{a}\| = \sup_{\|\boldsymbol{\theta}\| \leq 1} \boldsymbol{\theta} \mathbf{a} \leq \sup_{\|\boldsymbol{\theta}\| \leq 1} \kappa(\boldsymbol{\theta}) + c$$

es decir que $\{\kappa^*(\mathbf{a}) \leq c\}$ es acotado y compacto.

Puesto que $\kappa(\mathbf{0}) = 0$, es $\kappa^*(\mathbf{a}) \geq 0 \quad \forall \mathbf{a} \in \mathbb{R}^d$. Desde luego $\kappa^*(\mathbf{a}) = 0$ equivale a $\boldsymbol{\theta} \mathbf{a} \leq \kappa(\boldsymbol{\theta}) \quad \forall \boldsymbol{\theta} \in \mathbb{R}^d$. Y el conjunto $\{\mathbf{a} \in \mathbb{R}^d : \boldsymbol{\theta} \mathbf{a} \leq \kappa(\boldsymbol{\theta}) \quad \forall \boldsymbol{\theta} \in \mathbb{R}^d\}$ no es vacío pues siempre hay hiperplanos tangentes a $\kappa(\boldsymbol{\theta})$ en el punto $\boldsymbol{\theta} = \mathbf{0}$. $\square$

Teorema 21 (Gärtner–Ellis).

Si se cumple (H') , para cualquier cerrado $C \subset \mathbb{R}^d$,

$$\limsup_n \frac{1}{v_n} \log P_n\{\mathbf{X}_n/v_n \in C\} \leq -\kappa^*(C) = -\inf_{\mathbf{a} \in C} \kappa^*(\mathbf{a}). \quad (19)$$

Además, si $\kappa(\boldsymbol{\theta})$ es diferenciable $\forall \boldsymbol{\theta} \in \mathbb{R}^d$, para todo abierto $A \subset \mathbb{R}^d$,

$$\liminf_n \frac{1}{v_n} \log P_n\{\mathbf{X}_n/v_n \in A\} \geq -\kappa^*(A) = -\inf_{\mathbf{a} \in A} \kappa^*(\mathbf{a}) \quad (20)$$

$\therefore$ Solo se expondrá la demostración para el caso $d = 1$; para $d > 1$ el razonamiento sigue las mismas pautas y los detalles pueden verse en [3, § VII.4].

(1) Dado que $\kappa(\theta)$ es convexa existen las derivadas, $\kappa'_+(0)$ y $\kappa'_-(0)$ por la derecha y por la izquierda en el origen. Consideremos primero el cerrado $C = [a, \infty)$ donde $a > \kappa'_+(0)$; de acuerdo con la desigualdad de Markov:

$$P_n\{X_n/v_n \geq a\} \leq e^{-v_n \theta a} E_n[e^{\theta X_n}] = e^{-v_n[\theta a - \kappa_n(\theta)]}$$

para cualquier $\theta > 0$; por tanto

$$\limsup_n \frac{1}{v_n} \log P_n\{X_n/v_n \geq a\} \leq \inf_{\theta > 0} [-(\theta a - \kappa(\theta))] = -\sup_{\theta > 0} [\theta a - \kappa(\theta)].$$

Ahora bien, como κ es convexa y $\kappa(0) = 0$, para $\lambda \in (0, 1)$ es $\kappa(\lambda\theta) \leq \lambda\kappa(\theta)$ o bien, para $\theta < 0$ es $\kappa(\lambda\theta)/\lambda\theta \geq \kappa(\theta)/\theta$; cuando $\lambda \downarrow 0$ resulta $\kappa'_-(0) \geq \kappa(\theta)/\theta$. Entonces

$$\theta a - \kappa(\theta) = \theta[a - \kappa(\theta)/\theta] \leq \theta[a - \kappa'_-(0)] < 0 \quad \forall \theta < 0$$

puesto que $a > \kappa'_+(0) \geq \kappa'_-(0)$. De ahí que $\sup_{\theta > 0} [\theta a - \kappa(\theta)] = \kappa^*(a)$.

Análogo resultado para $C = (-\infty, a]$ si $a < \kappa'_-(0)$: $\kappa^*(a) = \sup_{\theta < 0} [\theta a - \kappa(\theta)]$.




Figura 1: $\kappa(\theta)$ y $\kappa^*(a)$

Cabe interpretar ambas conclusiones sobre la figura que muestra, además, que $\kappa^*(a)$ decrece en $(-\infty, \kappa'_-(0)]$, se anula en $[\kappa'_-(0), \kappa'_+(0)]$ y crece en $[\kappa'_+(0), \infty)$. En cualquier caso se cumple (19).

(2) Se supone ahora que $\kappa(\theta)$ es diferenciable incluyendo primero la hipótesis de que $\kappa'(\theta)$ puede tomar cualquier valor de $\mathbb{R}$. Si A es abierto y $a \in A$, hay un entorno $B(a, \varepsilon) = (a - \varepsilon, a + \varepsilon) \subset A$. Se consideran las probabilidades

$$Q_n(B) = P_n\{X_n/v_n \in B\} \quad \text{y} \quad Q_{n,\theta}(B) = \frac{1}{Z_n(\theta)} \int_B e^{v_n \theta x} Q_n(dx)$$

donde $Z_n(\theta) = \int_{\mathbb{R}} e^{v_n \theta x} Q_n(dx) = e^{v_n \kappa_n(\theta)}$; así que $Z_n(\theta) e^{-v_n \theta x}$ es la densidad de Q_n respecto a $Q_{n,\theta}$. Entonces, para cualquier $\theta \in \mathbb{R}$, es

$$\begin{aligned} Q_n(A) &\geq Q_n(B(a, \varepsilon)) = Z_n(\theta) \int_{a-\varepsilon}^{a+\varepsilon} e^{-v_n \theta x} Q_{n,\theta}(dx) \\ &\geq \exp\{v_n[\kappa_n(\theta) - \theta a] - v_n|\theta|\varepsilon\} Q_{n,\theta}(B(a, \varepsilon)) \end{aligned}$$

con lo cual

$$\begin{aligned} \liminf_n \frac{1}{v_n} \log Q_n(A) &\geq \kappa(\theta) - \theta a - |\theta|\varepsilon + \liminf_n \frac{1}{v_n} \log Q_{n,\theta}(B(a, \varepsilon)) \\ &\geq -\kappa^*(a) - |\theta|\varepsilon + \liminf_n \frac{1}{v_n} \log Q_{n,\theta}(B(a, \varepsilon)). \end{aligned}$$

Puesto que ε puede ser arbitrariamente pequeño y $a \in A$ es también arbitrario, para concluir

$$\liminf_n \frac{1}{v_n} \log Q_n(A) \geq -\kappa^*(A)$$

basta probar que $\lim_n Q_{n,\theta}(B(a, \varepsilon)) = 1$. Y, en efecto, si θ es tal que $\kappa'(\theta) = a$, como

$$\begin{aligned} \kappa_\theta(\eta) &:= \lim_n \frac{1}{v_n} \log \int_{\mathbb{R}} e^{v_n \eta x} Q_{n,\theta}(dx) \\ &= \lim_n \frac{1}{v_n} \log \int_{\mathbb{R}} e^{v_n(\eta+\theta)x} Q_n(dx) e^{-v_n \kappa_n(\theta)} = \kappa(\eta + \theta) - \kappa(\theta) \end{aligned}$$

resulta que $\kappa_\theta(\eta)$ es diferenciable y $\kappa'_\theta(0) = \kappa'(\theta) = a$. Ello implica que ηa es la única recta tangente a $\kappa_\theta(\eta)$ en $\eta = 0$ y κ_θ^* solo alcanza su mínimo 0 en el punto a . Además, $\kappa_\theta(\eta) < \infty \quad \forall \eta \in \mathbb{R}$ (o sea se cumple la hipótesis **H'**), luego la afirmación (19) (ya establecida) permite concluir

$$\limsup_n \frac{1}{v_n} \log Q_{n,\theta}(C) \leq -\kappa^*(C) \quad \text{o bien} \quad Q_{n,\theta}(C) \leq e^{-v_n \kappa^*(C)} \quad \forall n > n_0$$

para todo cerrado C y, en particular, para $C = B(a, \varepsilon)^c$, en cuyo caso $\kappa^*(C) > 0$. Así pues $Q_{n,\theta}(B(a, \varepsilon)) \rightarrow 1$. $\square$

Las últimas líneas de la demostración dan idea de que cualquiera de las afirmaciones equivalentes:

- i) $\kappa(\theta)$ es diferenciable en $\theta = \mathbf{0}$ y $\kappa'(\mathbf{0}) = \mathbf{a}$;
- ii) $\kappa^*(\mathbf{a})$ alcanza su mínimo 0 únicamente en el punto $\mathbf{a}$.

implican

- iii) $\forall \varepsilon > 0$ existe una constante M tal que $P_n\{\|\mathbf{X}_n/v_n - \mathbf{a}\| \geq \varepsilon\} \leq e^{-v_n M}$ si n es suficientemente grande; afirmación que se abrevia $\mathbf{X}_n/v_n \xrightarrow{\text{exp}} \mathbf{a}$.


Recíprocamente [3, § VII.6] prueba que de (iii) se deduce (i).

Un ejemplo sencillo prueba la necesidad de que $\kappa(\theta)$ sea diferenciable para que se verifique (20).

Ejemplo 1

Para cada $n \in \mathbb{N}$ sea $P_n\{X_n = n\} = p_n$ y $P_n\{X_n = -n\} = 1 - p_n$. En tal caso

$$\kappa(\theta) = \frac{1}{n} \log (p_n e^{n\theta} + (1 - p_n) e^{-n\theta}) = |\theta|.$$



Como se ve en la figura $\kappa^*(a) = \sup_{\theta} \{\theta a - |\theta|\} = \begin{cases} 0 & \text{si } |a| \leq 1, \\ \infty & \text{si } |a| > 1. \end{cases}$

Así pues, para $A \subset (-1, 1)$ es

$$\frac{1}{n} \log P_n\{X_n/n \in A\} = -\infty \quad \text{mientras que} \quad \kappa^*(A) = 0$$


y no se cumple (20).

Ejemplo 2

Si X_n tiene distribución de Poisson de parámetro n es

$$E_n[e^{\theta X_n}] = \exp\{n(e^{\theta} - 1)\} \quad \text{y} \quad \kappa_n(\theta) = \frac{1}{n} \log E_n[e^{\theta X_n}] = e^{\theta} - 1$$


de modo que $\kappa(\theta) = e^{\theta} - 1$ es diferenciable en todo $\mathbb{R}$.



Para $a \geq 0$, $\theta a - \kappa(\theta) = a\theta - e^{\theta} + 1$ alcanza su máximo en $\theta_a = \log a$; en cambio para $a < 0$, $\theta a - \kappa(\theta)$ no está acotado. Es decir

$$\kappa^*(a) = \begin{cases} a \log a - a + 1 & \text{si } a \geq 1, \\ \infty & \text{si } a < 1. \end{cases}$$

En particular $\kappa^*(1) = 0$.



Si A es cualquier subintervalo de $(0, 1)$ o de $(1, \infty)$, tal que $1 \notin \bar{A}$, y a_0 es el extremo más próximo a $a = 1$, será

$$\frac{1}{n} \log P_n\{X_n/n \in A\} = -(a_0 \log a_0 - a_0 + 1)$$

o bien

$$P_n\{X_n/n \in A\} = e^{-n(a_0 \log a_0 - a_0 + 1)} \quad (21)$$

ya que se cumplen (19) y (20) con $\bar{A}$ y A° respectivamente, siendo $\kappa^*(\bar{A}) = \kappa^*(A^\circ)$. En cambio, si $1 \in \bar{A}$ es $P_n\{X_n/n \in A\} = 1$. Se sigue que $X_n/n \rightarrow 1$ en probabilidad; ello puede deducirse, mediante el teorema de continuidad, de ser

$$E_n[e^{itX_n/n}] = e^{n(e^{it/n} - 1)} \rightarrow e^{it},$$

recordando que la convergencia en distribución a una constante equivale a la convergencia en probabilidad. Lo que añade (21) es la forma en que decrece $P_n\{X_n/n \in A\}$ cuando $1 \notin \bar{A}$.

Por supuesto, para $A \subset (-\infty, 0)$ es $P_n\{X_n/n \in A\} = 0$, lo cual coincide con $e^{-n\infty} = e^{-n\kappa^*(a)} \forall a \in A$.

Referencias

- [1] Dupuis, P. – Ellis, R.S. (1997): *A Weak Convergence Approach to the Theory of Large Deviations*. Wiley. (Cáp. 1)
- [2] Ellis, R.S. (2006): *The Theory of Large Deviations and Applications to Statistical Mechanics*. Lectures for the International Seminar on Extreme Events in Complex Dynamics.
- [3] Ellis, R.S. (2006): *Entropy, Large Deviations, and Statistical Mechanics*. Springer–Verlag. Classics in Mathematics.

Apéndice: El Teorema de Lusin

Teorema 22 (Lusin) Sea $g : E \mapsto \mathbb{R}$ una función medible (respecto a la σ -álgebra de Borel $\mathcal{E}$) y μ una medida finita en $(E, \mathcal{E})$:

- (a) para cada $\delta > 0$, existe una función continua $\gamma : E \mapsto \mathbb{R}$ tal que $\mu\{g \neq \gamma\} < \delta$ y, cuando g es acotada, se puede tomar $\sup |\gamma| \leq \sup |g|$;
- (b) existe una sucesión γ_n de funciones continuas que convergen a g salvo en un conjunto de medida μ nula y que cumplen $|\gamma_n| \leq \sup |g|$;
- (c) para cada $\delta > 0$, existe un cerrado C y una función continua $\gamma : E \mapsto \mathbb{R}$ tal que $\mu(E - C) \leq \delta$ y $g = \gamma$ en C .

$\therefore$ Supóngase primero que $0 \leq g \leq 1$, y sean $u_n = \sum_{j=1}^{2^n} (j-1)2^{-n} \mathbf{I}_{\{(j-1)2^{-n} \leq g < j2^{-n}\}}$ funciones simples que crecen hacia g ; por tanto, llamando $v_n = u_n - u_{n-1}$, será $g = \sum_{n=1}^{\infty} v_n$ y v_n solo puede valer 0 o 2^{-n} . Como μ es regular, para $A_n = \{v_n \neq 0\}$, existen $C_n \subset A_n \subset V_n$, con C_n cerrado y V_n abierto, tales que $\mu(V_n - C_n) < \delta 2^{-n}$; además, si $r_n = \inf\{d(x, y) : x \in C_n, y \in V_n^c\}$ es la distancia de C_n a V_n^c , la función $w_n(x) = \min\{d(x, V_n^c)/r_n, 1\}$ es continua, vale 0 en V_n^c , 1 en C_n y toma un valor intermedio en $V_n - C_n$. Entonces $\gamma(x) = \sum_{n=1}^{\infty} 2^{-n} w_n(x)$ es una función continua, puesto que la serie converge uniformemente. Desde luego $\mu(\bigcup_{n=1}^{\infty} (V_n - C_n)) < \delta$ y, si $x \notin \bigcup_{n=1}^{\infty} (V_n - C_n)$, para cada n puede ser $x \notin V_n$ en cuyo caso $w_n(x) = 0 = v_n(x)$

ya que $x \notin A_n$, o bien $x \in C_n$ en cuyo caso $w_n(x) = 1 = 2^n v_n(x)$ ya que $x \in A_n$. Así pues, $\gamma(x) = g(x) \forall x \notin \bigcup_{n=1}^{\infty} (V_n - C_n)$.

En caso de que sea $-M \leq g \leq M$, será $0 \leq (g + M)/2M \leq 1$ y, si γ' es continua y tal que $\mu\{(g + M)/2M \neq \gamma'\} < \delta$, resulta $\mu\{g \neq \gamma\} < \delta$ siendo $\gamma = 2M\gamma' - M$.

Por último, si g no es acotada, sean $g_1 = g \mathbf{I}_{\{|g| < n\}}$ y $g_2 = g \mathbf{I}_{\{|g| \geq n\}}$, tomando n suficientemente grande se puede conseguir que sea $\mu\{g_2 \neq 0\} = \mu\{|g| \geq n\} < \delta/2$ y, si γ es continua y tal que $\mu\{g_1 \neq \gamma\} < \delta/2$, será $\mu\{g \neq \gamma\} < \delta$.

En cualquier caso, si $\sup |g| = M$, cambiando γ por $\gamma' = \gamma \mathbf{I}_{\{|\gamma| \leq M\}} + M \frac{\gamma}{|\gamma|} \mathbf{I}_{\{|\gamma| > M\}}$ se obtiene una función continua, con $|\gamma'| \leq M$ y, como $\{\gamma = g\} \subset \{\gamma' = g\}$ (porque $|\gamma| \leq M$) y $\gamma = \gamma'$, se verifica $\mu\{g \neq \gamma'\} \leq \mu\{g \neq \gamma\} < \delta$.

(b) Según (a), existen funciones continuas γ_n , con $|\gamma_n| \leq \sup |g|$, y tales que se cumple $\mu\{\gamma_n \neq g\} < 2^{-n}$. Según el lema de Borel–Cantelli, $A = \limsup \{\gamma_n \neq g\}$ tiene medida nula y, si $x \notin A$, existe n_0 tal que $\gamma_n(x) = g(x) \forall n \geq n_0$.

(c) Aplicando (a), sea γ la función continua tal que $\mu\{g \neq \gamma\} < \delta/2$; puesto que $\mu\{g = \gamma\} = \sup \{\mu(C) : C \text{ cerrado y } C \subset \{g = \gamma\}\}$ se puede encontrar un cerrado $C \subset \{g = \gamma\}$ tal que $\mu(C) > \mu\{g = \gamma\} - \delta/2$. Entonces $\mu(C) > \mu(E) - \delta$. $\square$